70610301 Kompyuter injiniringi
Sun'iy intellektga asoslangan kompyuter tizimlari muhandisligi

LABORATORIYA ISHI · A6

Sun'iy intellekt tizimlarining xavfsizligi va ishonchliligini tahlil qilish

Bajarish bo‘yicha qo‘llanma: 7 bosqich · 10 mashq · 20 mustaqil variant

Kodlar va topshiriqlar: https://github.com/sayka7/ktm_labs/tree/main/A6
Fan sayti (virtual laboratoriya): https://aiscan.airi.uz/ktm/#/c/mis2104/lab/A6
O‘qituvchi: S.Iskandarova, t.f.f.d. (PhD), dotsent
2026-2027 o‘quv yili

Laboratoriya haqida

Bu virtual laboratoriyada talaba sklearn digits (8x8 rasm) ustida kichik PyTorch MLP'ga FGSM va PGD hujumlarini qo'lda yozadi, aniqlikning epsilon'ga bog'liqlik egri chizig'ini quradi, qisqa adversarial o'qitish bilan mustahkamlikni taqqoslaydi, Grad-CAM o'rniga gradient-saliency xaritasini chizadi, sintetik «kredit» ma'lumotida fairlearn MetricFrame va ThresholdOptimizer bilan adolatlilikni o'lchaydi va tuzatadi, shap TreeExplainer bilan daraxt modelini tushuntiradi hamda 20 bandli etik tekshiruv ro'yxatini avtomatik baholaydi. Real labdan farqi: CIFAR-10/ResNet-18 va Adult o'rniga kichik, tarmoqsiz yuklanadigan ma'lumotlar; torchattacks va grad-cam kutubxonalari yo'q — hujumlar va saliency qo'lda yoziladi (bu o'rganish uchun foydaliroq).

> **Muhit.** Muhit: Python 3.12, CPU (2 yadro, 1,5 GB), tarmoq yo'q, vaqt chegarasi 90 s. Kutubxonalar: torch, torchvision, numpy, pandas, scipy, scikit-learn, matplotlib, onnx, onnxruntime, fairlearn, shap, numba, psutil, pyyaml, fastapi, httpx.

Bajarish tartibi

1. Kodlarni oling: `git clone https://github.com/sayka7/ktm_labs.git` (yoki GitHub'dan «Download ZIP», yoki saytdagi ZIP) va `cd ktm_labs/A6`.
2. Kutubxonalar: `python3 -m venv venv && source venv/bin/activate`, so‘ng `pip install -r ../requirements.txt` (bir marta, ~2 GB).
3. Har bosqichda karkas (`s1_*.py`) berilgan: avval yo‘naltiruvchi savollarga o‘zingiz javob bering, so‘ng **TODO** joylarini to‘ldirib, `python3 s1_*.py` bilan ishga tushiring. Qiynalsangiz — qo‘llanma oxiridagi «Ishoralar» ilovasiga qarang. Natijani «Mening natijam» joyiga yozing.
4. Saytda ham bajarish mumkin (o‘rnatishsiz): https://aiscan.airi.uz/ktm/ → Mavzular → A6 → 🧪 Virtual bajarish.
5. Mashqlar va o‘z variantingizni (jurnal raqami bo‘yicha) bajarib, hisobotni topshiring.

Mundarija

1. 1-qadam. Bazaviy model va FGSM: aniqlikning epsilon'ga bog'liqligi
2. 2-qadam. PGD hujumini qo'lda yozish va FGSM bilan taqqoslash
3. 3-qadam. Adversarial o'qitish (qisqa) va mustahkamlik murozasi
4. 4-qadam. Gradient-saliency xaritasi: toza va hujum ostidagi raqamlar
5. 5-qadam. Adolatlilik: MetricFrame va ThresholdOptimizer
6. 6-qadam. SHAP TreeExplainer: global muhimlik, lokal izoh, additivlik
7. 7-qadam. Etik tekshiruv ro'yxatini avtomatik baholash
8. Qo‘shimcha mashqlar (10)
9. Mustaqil topshiriqlar — 20 variant

1 1-qadam. Bazaviy model va FGSM: aniqlikning epsilon'ga bog'liqligi

MAQSAD

Digits ma'lumoti [0,1] piksel fazosiga keltiriladi (1 kulrang daraja = 1/16), MLP 300 qadam Adam bilan o'qitiladi (test ~97%). FGSM qo'lda yoziladi: `x + eps*sign(grad)`, [0,1] ga qirqish. 7 ta epsilon uchun aniqlik jadvali va mustahkamlik egri chizig'i chiziladi; shu eps'dagi tasodifiy ±eps shovqin bilan taqqoslanadi. Talaba model chuqurligini, epsilon to'rini va o'qitish qadamlarini o'zgartirib ko'radi.

> **Kutilgan natija:** eps=0.05 da aniqlik ~0.77, eps=0.1 da ~0.3, eps=0.15 da ~0.1; tasodifiy shovqin eps=0.15 da ~0.93 qoldiradi. Grafik: keskin tushuvchi egri chiziq.

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. Hujumchi har pikselni ko'pi bilan eps ga o'zgartira oladi (L_inf chegarasi). eps = 0.0625 piksel fazosida nimani anglatadi va nega ma'lumot [0,1] ga keltirilgan?

2. Yo'qotishni oshirish uchun pikselni qaysi yo'nalishda siljitish kerak? Gradientning faqat ishorasini olish L_inf chegarasi bilan qanday bog'liq?

3. Model parametrlari emas, kirish bo'yicha gradientni qanday olasiz? x qanday tayyorlanishi kerak?

4. Buzilgan rasm qiymatlari [0,1] dan chiqib ketsa nima bo'ladi? Natijani grafikdan uzish (detach) nega kerak?

5. Xuddi shu eps dagi tasodifiy ±eps shovqin aniqlikni qancha tushiradi deb o'ylaysiz? Bu taqqoslash nimani isbotlaydi?

6. Natijani qanday tekshirasiz: eps = 0.05, 0.1, 0.15 da aniqlik qancha atrofida bo'lishi va tasodifiy shovqin qancha qoldirishi kerak?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S1_*.PY)

```
# 1-qadam. Bazaviy model (digits 8x8, MLP) va FGSM hujumi: aniqlikning epsilon ga bog'liqligi
# Piksellar [0,1] oraliqqa keltiriladi (data/16) — 1 kulrang daraja = 1/16 = 0.0625.
import torch, torch.nn as nn, torch.nn.functional as F, numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
torch.manual_seed(0); torch.set_num_threads(2)
```

```
d = load_digits()
Xtr, Xte, ytr, yte = train_test_split(d.data / 16.0, d.target, test_size=0.3, random_state=0,
stratify=d.target)
Xtr, Xte = torch.tensor(Xtr, dtype=torch.float32), torch.tensor(Xte, dtype=torch.float32)
ytr, yte = torch.tensor(ytr), torch.tensor(yte)

def train(X, y, steps=300):
    m = nn.Sequential(nn.Linear(64, 128), nn.ReLU(), nn.Linear(128, 64), nn.ReLU(),
nn.Linear(64, 10))
    opt = torch.optim.Adam(m.parameters(), lr=3e-3)
    for _ in range(steps):
        opt.zero_grad(); F.cross_entropy(m(X), y).backward(); opt.step()
    return m.eval()

def fgsm(model, x, y, eps):
    """x_adv = ? — bitta gradient qadami, [0,1] ga qirqiladi."""
    # TODO 1: x bo'yicha yo'qotish gradientini oling va eps * sign(grad) qadamini qo'yib, [0,1]
ga qirqing
    raise NotImplementedError("TODO 1: FGSM")

def acc(model, x, y):
    with torch.no_grad(): return (model(x).argmax(1) == y).float().mean().item()

model = train(Xtr, ytr)
print(f"Toza aniqlik: o'quv={acc(model, Xtr, ytr):.3f}  test={acc(model, Xte, yte):.3f}")
EPS = [0.0, 0.02, 0.05, 0.1, 0.15, 0.2, 0.3]
print("=== FGSM: aniqlik vs epsilon ===")
res = []
# TODO 2: har eps uchun hujumli test to'plamida aniqlik va o'rtacha L_inf masofani chiqaring
(res ga yig'ing)
for e in EPS:
    xa = fgsm(model, Xte, yte, e) if e > 0 else Xte
# TODO 3: eps=0.15 da tasodifiy +-eps shovqin bilan taqqoslang ("Taqqoslash eps=..." qatori) va
egri chiziqni chizing
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== FGSM: aniqlik vs epsilon ===`, `Taqqoslash eps=`

TAJRIBA QILIB KO‘RING

- `train(..., steps=50)` — kam o'qitilgan model hujumga ko'proq yoki kamroq chidamlimi?
- Modelga `nn.Dropout(0.3)` qo'shing va eval rejimini unutib (`model.train()`), FGSM aniqligini solishtiring — «soxta mustahkamlik».
- Yo'naltirilgan (targeted) FGSM yozing: gradient ishorasini teskari olib, maqsad sinf yo'qotishini kamaytiring.

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

2 2-qadam. PGD hujumini qo'lda yozish va FGSM bilan taqqoslash

MAQSAD

PGD: tasodifiy boshlang'ich nuqta, K qadam `alpha*sign(grad)`, har qadimdan keyin eps-sharga proyeksiya va [0,1] qirqish. FGSM, PGD-10 (tasodifiy boshlanish bilan/siz) va PGD-40 bir xil epsilon to'rida solishtiriladi, har hujum uchun L_inf chegarasi `assert` bilan tekshiriladi. Talaba alpha, qadamlar soni va boshlang'ich nuqtaning ta'sirini ko'radi.

> **Kutilgan natija:** PGD har eps'da FGSM dan past yoki teng aniqlik beradi (eps=0.15: FGSM ~0.11, PGD ~0.05; eps=0.2: PGD ~0.00). Assert o'tadi. 4 egri chiziqli grafik.

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. FGSM bitta katta qadam qiladi. Agar yo'qotish sirti egri bo'lsa, bitta qadam nega optimal bo'lmasligi mumkin? PGD bu muammoni qanday hal qiladi?

2. Bir necha qadamdan keyin buzilish eps dan oshib ketishi mumkin. Har qadamdan keyin nuqtani ruxsat etilgan sohaga qanday qaytarasiz?

3. Tasodifiy boshlang'ich nuqta nima uchun kerak? Toza nuqtadan boshlansa, gradient nimaga 'yopishib' qolishi mumkin?

4. Tsikl ichida har qadamda grafik nega uzilishi (detach) va requires_grad qayta yoqilishi kerak? Aks holda nima bo'ladi?

5. Hujumingiz tahdid modelini buzmaganini qanday kafolatlaysiz? Qaysi kattalikni eps bilan solishtirasiz?

6. Natijalaringiz to'g'riligini qanday bilasiz: PGD va FGSM orasida qanday tartib kutiladi, eps=0.15 va 0.2 da qanday aniqliklar?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S2_*.PY)

```
# 2-qadam. PGD hujumini qo'lda amalga oshirish va FGSM bilan taqqoslash
import torch, torch.nn as nn, torch.nn.functional as F, numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
torch.manual_seed(0); torch.set_num_threads(2)

d = load_digits()
Xtr, Xte, ytr, yte = train_test_split(d.data / 16.0, d.target, test_size=0.3, random_state=0,
```

```
stratify=d.target)
Xtr, Xte = torch.tensor(Xtr, dtype=torch.float32), torch.tensor(Xte, dtype=torch.float32)
ytr, yte = torch.tensor(ytr), torch.tensor(yte)

def train(X, y, steps=300):
    m = nn.Sequential(nn.Linear(64, 128), nn.ReLU(), nn.Linear(128, 64), nn.ReLU(),
nn.Linear(64, 10))
    opt = torch.optim.Adam(m.parameters(), lr=3e-3)
    for _ in range(steps):
        opt.zero_grad(); F.cross_entropy(m(X), y).backward(); opt.step()
    return m.eval()

def fgsm(model, x, y, eps):
    x = x.clone().detach().requires_grad_(True)
    grad, = torch.autograd.grad(F.cross_entropy(model(x), y), x)
    return (x + eps * grad.sign()).clamp(0, 1).detach()

def pgd(model, x, y, eps, alpha=None, steps=10, random_start=True):
    """Iterativ FGSM + proyeksiya: har qadamdan keyin x atrofidagi eps-sharga va [0,1] ga
qaytariladi."""
    alpha = alpha or 2.5 * eps / steps
    # TODO 1: boshlang'ich nuqta — random_start bo'lsa x + U(-eps, eps), aks holda x; [0,1] ga
qirqing
    # TODO 2: steps marta: gradient, alpha * sign(grad) qadami
    # TODO 3: har qadamdan keyin [x-eps, x+eps] sharga proyeksiya va [0,1] qirqish
    raise NotImplementedError("TODO 1-3: PGD")

def acc(model, x, y):
    with torch.no_grad(): return (model(x).argmax(1) == y).float().mean().item()

model = train(Xtr, ytr)
EPS = [0.02, 0.05, 0.1, 0.15, 0.2]
attacks = {"FGSM": lambda e: fgsm(model, Xte, yte, e),
           "PGD-10 (tasodifiy boshlanmasdan)": lambda e: pgd(model, Xte, yte, e, steps=10,
random_start=False),
           "PGD-10": lambda e: pgd(model, Xte, yte, e, steps=10),
           "PGD-40": lambda e: pgd(model, Xte, yte, e, steps=40)}
print("=== Aniqlik: FGSM vs PGD (epsilon bo'yicha) ===")
curves = {}
for name, fn in attacks.items():
    row = []
    for e in EPS:
        torch.manual_seed(1); xa = fn(e)
        # TODO 4: L_inf chegarasini assert bilan tekshiring va aniqlikni row ga qo'shing
    curves[name] = row
print("L_inf chegarasi barcha hujumlarda saqlangan (assert o'tdi).")
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== Aniqlik: FGSM vs PGD`, `L_inf chegarasi barcha hujumlarda saqlangan`

TAJRIBA QILIB KO‘RING

- `alpha = eps` (juda katta qadam) qilib PGD kuchsizlanishini kuzating.
- Proyeksiya satrini olib tashlang — assert nega yiqiladi?
- L_2 normali PGD yozing: gradientni normalashtirib, buzilishni eps radiusli sharga proyeksiya qiling.

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

3 3-qadam. Adversarial o'qitish (qisqa) va mustahkamlik murozasi

MAQSAD

Madry uslubi: har qadamda avval PGD-5 (eps=0.1) bilan adversarial o'quv paketi yasaladi, model aynan unda o'qitiladi. Toza va adversarial modellar FGSM/PGD-10 ostida 5 ta eps uchun taqqoslanadi (4 egri chiziq), o'qitish vaqti nisbati chiqadi. Talaba EPS_TRAIN, k va qadamlar sonini o'zgartirib, murozani o'rganadi.

> **Kutilgan natija:** Adversarial o'qitish ~6x qimmat; PGD-10 eps=0.1 ostida aniqlik ~0.27 dan ~0.83 ga ko'tariladi; eps=0.2 da himoya zaiflashadi (~0.2).

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. Adversarial o'qitish qanday min-max masala sifatida yoziladi? Ichki 'max' va tashqi 'min' kim tomonidan bajariladi?

2. Har o'qitish qadamida adversarial paketni qaysi model nusxasi bilan yasash kerak — eski (boshlang'ich) yoki joriy model bilan? Nega?

3. Bitta adversarial o'qitish qadami toza qadamdan necha baravar qimmat bo'lishini kutasiz, agar PGD-5 ishlatilsa?

4. Ikkala modelni adolatli taqqoslash uchun nimalar bir xil bo'lishi kerak (boshlang'ich og'irliklar, hujum, urug')?

5. Himoya eps=0.1 da o'qitilgan bo'lsa, eps=0.2 hujumida nima bo'lishini kutasiz? Bu 'tahdid modeli' tushunchasi haqida nimani aytadi?

6. Natijani qanday tekshirasiz: o'qitish narxi, PGD-10 eps=0.1 ostidagi aniqlik qanday o'zgarishi kerak?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S3_*.PY)

```
# 3-qadam. Adversarial o'qitish (Madry uslubi, qisqa) va mustahkamlikni taqqoslash
import time, torch, torch.nn as nn, torch.nn.functional as F
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
torch.manual_seed(0); torch.set_num_threads(2)

d = load_digits()
Xtr, Xte, ytr, yte = train_test_split(d.data / 16.0, d.target, test_size=0.3, random_state=0,
```

```
stratify=d.target)
Xtr, Xte = torch.tensor(Xtr, dtype=torch.float32), torch.tensor(Xte, dtype=torch.float32)
ytr, yte = torch.tensor(ytr), torch.tensor(yte)
EPS_TRAIN = 0.1                      # o'qitishdagi tahdid modeli

def new_model():
    torch.manual_seed(0)
    return nn.Sequential(nn.Linear(64, 128), nn.ReLU(), nn.Linear(128, 64), nn.ReLU(),
nn.Linear(64, 10))

def pgd(model, x, y, eps, steps=10, random_start=True):
    alpha = 2.5 * eps / steps
    x0 = x.clone().detach()
    xa = (x0 + torch.empty_like(x0).uniform_(-eps, eps)).clamp(0, 1) if random_start else
x0.clone()
    for _ in range(steps):
        xa.requires_grad_(True)
        grad, = torch.autograd.grad(F.cross_entropy(model(xa), y), xa)
        xa = torch.min(torch.max(xa.detach() + alpha * grad.sign(), x0 - eps), x0 +
eps).clamp(0, 1)
    return xa.detach()

def fgsm(model, x, y, eps):
    x = x.clone().detach().requires_grad_(True)
    grad, = torch.autograd.grad(F.cross_entropy(model(x), y), x)
    return (x + eps * grad.sign()).clamp(0, 1).detach()

def train(adv=False, steps=300, k=5):
    """adv=True: har qadamda avval PGD-k bilan adversarial paket yasaladi, model aynan unda
o'qitiladi (min-max)."""
    # TODO 1: model va Adam yarating, vaqtni o'lchang
    # TODO 2: har qadamda adv bo'lsa PGD-k (EPS_TRAIN) bilan o'quv paketini yasang (model eval
holatida), aks holda Xtr
    # TODO 3: model.train() holatida shu paketda bir optimizatsiya qadamini bajaring;
(model.eval(), vaqt) qaytaring
    raise NotImplementedError("TODO 1-3: adversarial o'qitish")

def acc(model, x, y):
    with torch.no_grad(): return (model(x).argmax(1) == y).float().mean().item()

clean, t_clean = train(adv=False)
robust, t_adv = train(adv=True)
EPS = [0.0, 0.05, 0.1, 0.15, 0.2]
print("=== Toza model vs adversarial o'qitilgan model ===")
curves = {k: [] for k in ("toza/FGSM", "toza/PGD", "adv/FGSM", "adv/PGD")}
# TODO 4: har eps va har model uchun FGSM va PGD-10 ostidagi aniqlikni curves ga yozing va
jadvalni chiqaring
# TODO 5: "Muroza:" qatori — toza aniqlik va PGD-10 (eps=EPS_TRAIN) ostidagi aniqlik qanday
o'zgardi
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== Toza model vs adversarial o'qitilgan model ===`, `Muroza:`

TAJRIBA QILIB KO‘RING

- EPS_TRAIN=0.05 va 0.2 bilan qayta o'qiting: himoya radiusi va toza aniqlik qanday o'zgaradi?
- k=1 (FGSM adversarial training) — «katastrofik overfitting» kuzatiladimi (FGSM'ga chidamli, PGD'ga zaif)?
- Toza va adversarial yo'qotishni 50/50 aralashtirib (TRADES-ga o'xshash) murozani yumshating.

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

4 4-qadam. Gradient-saliency xaritasi: toza va hujum ostidagi raqamlar

MAQSAD

MLP uchun Grad-CAM o'rniga gradient-saliency (|d logit/d x|, 8x8) hisoblanadi. 8 ta test raqami uchun toza rasm, uning saliency xaritasi, PGD (eps=0.15) bilan buzilgan rasm va uning xaritasi 4 qatorli panelda chiziladi; toza/adv xaritalar korrelyatsiyasi va entropiyasi jadvalda. Talaba tushuntirishning hujum ostida «ko'chishini» ko'radi.

> **Kutilgan natija:** Adversarial rasmlar ko'zga toza bilan deyarli bir xil, lekin bashorat noto'g'ri; saliency korrelyatsiyasi ~0 atrofida (xarita ko'chgan). Panel rasmi.

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. Saliency xaritasi qaysi savolga javob beradi: 'qaysi piksel kichik o'zgarsa, shu sinf bahosi eng ko'p o'zgaradi?' Bu qaysi hosilaga mos keladi?

2. 8 ta namuna uchun gradientni bitta autograd chaqiruvi bilan qanday olasiz? Har namunada boshqa sinf logitini qanday tanlaysiz?

3. Xarita 'tarqoq' yoki 'jamlangan' ekanini qanday son bilan o'lchash mumkin? Entropiya uchun xarita qanday ko'rinishga keltirilishi kerak?

4. Ikki 64 o'lchamli xaritaning o'xshashligini qanday baholaysiz? Korrelyatsiya ~1, ~0 yoki manfiy bo'lsa nimani anglatadi?

5. Nega adversarial xarita uchun saliency adv bashorat (p_adv) sinfi bo'yicha olinadi, haqiqiy sinf bo'yicha emas?

6. Natijangizni qanday baholaysiz: adversarial rasmlar ko'zga qanday ko'rinishi, bashoratlar va o'rtacha korrelyatsiya qancha bo'lishi kerak?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S4_*.PY)

```
# 4-qadam. Gradient-saliency xaritasi (Grad-CAM ning MLP uchun muqobili): toza va hujum
ostidagi raqamlar
# Saliency = |d logit_y / d x| — har piksel bashoratga qanchalik ta'sir qilishini ko'rsatadi.
import torch, torch.nn as nn, torch.nn.functional as F, numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
```

```
torch.manual_seed(0); torch.set_num_threads(2)

d = load_digits()
Xtr, Xte, ytr, yte = train_test_split(d.data / 16.0, d.target, test_size=0.3, random_state=0,
stratify=d.target)
Xtr, Xte = torch.tensor(Xtr, dtype=torch.float32), torch.tensor(Xte, dtype=torch.float32)
ytr, yte = torch.tensor(ytr), torch.tensor(yte)

m = nn.Sequential(nn.Linear(64, 128), nn.ReLU(), nn.Linear(128, 64), nn.ReLU(), nn.Linear(64,
10))
opt = torch.optim.Adam(m.parameters(), lr=3e-3)
for _ in range(300):
    opt.zero_grad(); F.cross_entropy(m(Xtr), ytr).backward(); opt.step()
m.eval()

def pgd(model, x, y, eps, steps=10):
    alpha = 2.5 * eps / steps; x0 = x.clone().detach()
    xa = (x0 + torch.empty_like(x0).uniform_(-eps, eps)).clamp(0, 1)
    for _ in range(steps):
        xa.requires_grad_(True)
        grad, = torch.autograd.grad(F.cross_entropy(model(xa), y), xa)
        xa = torch.min(torch.max(xa.detach() + alpha * grad.sign(), x0 - eps), x0 +
eps).clamp(0, 1)
    return xa.detach()

def saliency(model, x, cls):
    """Bashorat qilingan sinf logitining kirish bo'yicha gradienti moduli (8x8)."""
    # TODO 1: har namuna uchun cls sinf logitini tanlab, kirish bo'yicha gradientning modulini
qaytaring
    raise NotImplementedError("TODO 1: saliency")

def entropy(s):
    # TODO 2: xaritani ehtimollik taqsimotiga normallab, Shannon entropiyasini hisoblang (har
namuna uchun)
    raise NotImplementedError("TODO 2: entropy")

N = 8; x, y = Xte[:N], yte[:N]
xa = pgd(m, x, y, eps=0.15)
with torch.no_grad(): p_clean, p_adv = m(x).argmax(1), m(xa).argmax(1)
s_clean, s_adv = saliency(m, x, p_clean), saliency(m, xa, p_adv)
# TODO 3: har namuna uchun toza va adv xaritalar Pearson korrelyatsiyasini hisoblang
print("=== Saliency xaritasi: toza vs adversarial (eps=0.15) ===")
# TODO 4: jadval (haqiqiy, toza, adv bashorat, korr, entropiyalar) va "O'rtacha
korrelyatsiya=..." qatori; 4 qatorli panel rasmi
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== Saliency xaritasi: toza vs adversarial`, `O'rtacha korrelyatsiya=`

TAJRIBA QILIB KO‘RING

- SmoothGrad yozing: 20 ta shovqinli nusxa bo'yicha saliency o'rtachasi — xarita silliqroqmi?
- Adversarial o'qitilgan model (3-qadam) uchun xaritalarni solishtiring: korrelyatsiya yuqoriroq chiqadimi?
- Eng muhim 8 pikselni 0 qilib (deletion) bashorat ehtimoli qanchaga tushishini o'lchang — sodiqlik metrikasi.

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

5 5-qadam. Adolatlilik: MetricFrame va ThresholdOptimizer

MAQSAD

Sintetik kredit ma'lumotida sezgir atribut A, u bilan bog'liq vakil belgi (income) va tarixiy tarafkashlik (A=1 guruhda ijobiylarning 25% noto'g'ri rad etilgan) modellashtiriladi. Logistik regressiya uchun MetricFrame guruhlar kesimida aniqlik, tanlov ulushi, TPR, FPR beradi; DP va EO farqlari hisoblanadi. To'rt variant taqqoslanadi: A bilan, A siz (unawareness), ThresholdOptimizer DP va EO cheklovlari bilan.

> **Kutilgan natija:** Baza: DP farqi ~0.25, EO ~0.27; A olib tashlanganda DP ~0.13 (proxy orqali saqlanadi); ThresholdOptimizer(DP) DP ni ~0.01 ga, (EO) EO ni ~0.02 ga tushiradi, aniqlik 1-3 bandga pasayadi.

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. Ma'lumotda tarafkashlik qayerdan paydo bo'lgan: belgilarda, yorliqlarda yoki ikkalasidami? income qanday rol o'ynaydi?

2. Demographic parity (DP) va equalized odds (EO) farqlari qaysi kattaliklarni guruhlar orasida solishtiradi?

3. Metrikalarni guruh kesimida bitta jadvalda qanday olasiz? MetricFrame'ga nimalarni berish kerak?

4. A ni modeldan olib tashlasak, DP farqi yo'qoladimi? Agar yo'q bo'lsa, nima uchun?

5. Post-processing (ThresholdOptimizer) qanday ishlaydi: model o'zgaradimi yoki faqat qaror chegarasi? Inferensda unga nima qo'shimcha kerak?

6. Natijalarni qanday tekshirasiz: baza, unawareness va ikki ThresholdOptimizer varianti uchun DP/EO va aniqlik qanday o'zgarishi kerak?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S5_*.PY)

```
# 5-qadam. Adolatlilik: Fairlearn MetricFrame va ThresholdOptimizer (sintetik "kredit"
ma'lumoti)
# Sezgir atribut A (0/1). Tarixiy tarafkashlik: A=1 guruhda belgilangan maqsad (y) past
baholangan.
import numpy as np, pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from fairlearn.metrics import (MetricFrame, selection_rate, true_positive_rate,
false_positive_rate,
```

```
                                demographic_parity_difference, equalized_odds_difference)
from fairlearn.postprocessing import ThresholdOptimizer

# --- Berilgan ma'lumot generatori (o'zgartirmang)
rng = np.random.default_rng(0); n = 6000
A = rng.binomial(1, 0.4, n)                                # sezgir atribut
income = rng.normal(5.0 - 0.8 * A, 1.0, n)                 # A bilan bog'liq (vakil belgi —
proxy)
history = rng.normal(0, 1, n); debt = rng.normal(0, 1, n)
score = 0.9 * income + 1.0 * history - 0.8 * debt
y_true_ability = (score + rng.normal(0, 1, n) > 4.5).astype(int)
flip = (A == 1) & (y_true_ability == 1) & (rng.random(n) < 0.25)
y = np.where(flip, 0, y_true_ability)
X = pd.DataFrame({"income": income, "history": history, "debt": debt, "A": A})
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.4, random_state=0, stratify=y)
Atr, Ate = Xtr["A"].values, Xte["A"].values

def report(name, pred):
    # TODO 1: MetricFrame (aniqlik, tanlov, TPR, FPR) guruhlar kesimida; DP va EO farqlari;
(aniqlik, dp, eo) qaytaring
    raise NotImplementedError("TODO 1: report")

print("=== Adolatlilik tahlili (MetricFrame) ===")
rows = {}
# TODO 2: Baza — LogisticRegression barcha belgilar (A bilan)
# TODO 3: A olib tashlangan (unawareness) model
# TODO 4: ThresholdOptimizer (prefit, predict_proba) — demographic_parity va equalized_odds
cheklovlari
rows["Baza (A belgi sifatida kiradi)"] = report("Baza", None)

print("\n=== Yakuniy jadval ===")
for k, (a, dp, eo) in rows.items(): print(f"{k:42s} {a:8.4f} {dp:9.3f} {eo:9.3f}")
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== Adolatlilik tahlili (MetricFrame) ===`, `=== Yakuniy jadval ===`

TAJRIBA QILIB KO‘RING

- Tarafkashlik ulushini 0.25 dan 0 ga tushiring — bazaviy farq qoladimi (haqiqiy bazaviy ulush farqi tufayli)?
- `fairlearn.reductions.ExponentiatedGradient` + `EqualizedOdds(difference_bound=0.02)` bilan in-processing qo'shing va jadvalga kiriting.
- `income` ni belgilar ro'yxatidan ham olib tashlang: aniqlik va DP farqi qanday o'zgaradi?

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

6 6-qadam. SHAP TreeExplainer: global muhimlik, lokal izoh, additivlik

MAQSAD

breast_cancer (569x30) ustida GradientBoosting o'qitiladi, TreeExplainer log-odds fazosida SHAP qiymatlarini beradi. Global o'rtacha |SHAP| top-10, bitta namuna uchun top-6 hissalar, additivlik tekshiruvi (bazaviy + sum(SHAP) = decision_function, farq ~1e-15) va 1% shovqinda tushuntirish barqarorligi chiqadi; beeswarm grafigi chiziladi.

> **Kutilgan natija:** Aniqlik ~0.94; top belgilar: worst perimeter, worst concave points, mean concave points; additivlik farqi ~1e-15; barqarorlik ~0.99.

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. Shapley qiymati bitta belgining bashoratga hissasini qanday adolatli taqsimlaydi? TreeExplainer nega daraxt modellari uchun tez va aniq?

2. GradientBoosting uchun SHAP qiymatlari qaysi fazoda — ehtimollikdami yoki log-odds'dami? Ikki sinfli holatda natija shakli qanday bo'lishi mumkin?

3. Global muhimlikni lokal SHAP qiymatlaridan qanday yig'asiz? Nega oddiy o'rtacha emas, modul o'rtachasi olinadi?

4. Lokal aniqlik (additivlik) aksiomasi nimani talab qiladi? Uni bitta namuna uchun qanday tekshirasiz?

5. Tushuntirish ishonchliligini qanday baholash mumkin? Kirishga har belgining std'siga nisbatan 1 % shovqin qo'shsak, top-5 belgilar o'zgarishi kerakmi?

6. Natijani qanday tekshirasiz: aniqlik, eng muhim belgilar, additivlik farqi va barqarorlik qancha bo'lishi kerak?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S6_*.PY)

```
# 6-qadam. SHAP (TreeExplainer) bilan daraxt modelini tushuntirish: global muhimlik, lokal
izoh, additivlik
import numpy as np, pandas as pd, shap, matplotlib.pyplot as plt
from sklearn.datasets import load_breast_cancer
from sklearn.ensemble import GradientBoostingClassifier
from sklearn.model_selection import train_test_split

d = load_breast_cancer(as_frame=True)
```

```
X, y = d.data, d.target                                  # 569 namuna, 30 belgi, 1 = xavfsiz
(benign)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=0, stratify=y)
clf = GradientBoostingClassifier(n_estimators=150, max_depth=3, random_state=0).fit(Xtr, ytr)
print(f"Model aniqligi (test): {clf.score(Xte, yte):.4f}")

# TODO 1: TreeExplainer bilan test to'plami SHAP qiymatlari (n, 30) va bazaviy qiymat (log-
odds)
sv, base = None, None

print("=== SHAP: global muhimlik (o'rtacha |SHAP|) — top-10 ===")
# TODO 2: o'rtacha |SHAP| bo'yicha saralangan top-10 belgi
# TODO 3: test namunasi #0 uchun additivlik: base + sum(SHAP) va decision_function farqi
("Additivlik tekshiruvi: farq = ...");
#         eng katta 6 hissa (ishorasi bilan)
print(f"Additivlik tekshiruvi: farq = {abs(base + sv[0].sum()):.2e}")
# TODO 4: 1 % shovqin qo'shib top-5 belgilar mosligi (barqarorlik); beeswarm grafigi
(shap.summary_plot, show=False)
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== SHAP: global muhimlik`, `Additivlik tekshiruvi`

TAJRIBA QILIB KO‘RING

- RandomForestClassifier bilan takrorlang — TreeExplainer ehtimollik fazosida qaytaradi; additivlikni qayta tekshiring.
- Korrelyatsiyalangan belgilar (worst radius / worst perimeter / worst area) hissalari qanday taqsimlangan? Bittasini olib tashlab qayta o'qiting.
- `shap.KernelExplainer` bilan 20 namunada solishtiring va vaqt farqini o'lchang.

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

7 7-qadam. Etik tekshiruv ro'yxatini avtomatik baholash

MAQSAD

20 bandli ro'yxat (ISO/IEC 42001, 23894, EU AI Act, NIST AI RMF) skript bilan baholanadi: texnik bandlar (7, 8, 9, 11, 20) skript ichida tez o'lchangan metrikalardan (toza/FGSM aniqlik, DP/EO farqi, urug' va versiyalar) chegaralar bo'yicha avtomatik, tashkiliy bandlar talaba to'ldiradigan DALIL lug'atidan olinadi; dalilsiz «ha» avtomatik «qisman»ga tushiriladi. Umumiy ball /100 va xulosa chiqadi.

> **Kutilgan natija:** 20 qatorli jadval, umumiy ball ~60/100, bajarilmagan bandlar ro'yxati (masalan 9, 12, 14, 18) va xulosa.

YO‘NALTIRUVCHI SAVOLLAR (SUQROT USULI)

Kod yozishdan oldin har bir savolga o‘zingiz qisqa javob yozing — javoblar sizni yechimga olib boradi. Ishoralar — qo‘llanma oxirida.

1. 20 bandning qaysilarini kod bilan o'lchab bo'ladi, qaysilari faqat tashkiliy hujjat (dalil) bilan tasdiqlanadi? Nega bu ajratish muhim?

2. Texnik bandlar uchun qanday o'lchovlar kerak va ular avvalgi qadamlarning qaysi biriga mos keladi?

3. Band nomlaridagi chegaralar (EO<0.05, adv aniqlik >= 50 %) holatni qanday aniqlaydi? Chegaradan o'tmasa 'yo'q' yoki 'qisman' — qaysi biri adolatli?

4. Talaba DALIL'da 'ha' deb yozib, dalil matnini bo'sh qoldirsa, skript nima qilishi kerak? Nega 'dalilsiz ha' qabul qilinmaydi?

5. Umumiy ball qanday hisoblanadi va qaysi chegaralarda xulosa 'yetarli', 'qisman', 'qoniqarsiz' bo'ladi?

6. Natijani qanday tekshirasiz: umumiy ball qancha atrofida va qaysi bandlar bajarilmagan bo'lishi kerak? Ular yuqori xavfli tizim uchun nega muhim?

KARKAS — TODO JOYLARINI TO‘LDIRING (FAYL: S7_*.PY)

```
# 7-qadam. Etik tekshiruv ro'yxatini (20 band) avtomatik baholovchi skript
# Texnik bandlar (7, 8, 9, 11, 20) o'lchov natijalaridan avtomatik aniqlanadi; tashkiliy
bandlar DALIL lug'atidan.
import numpy as np, torch, torch.nn as nn, torch.nn.functional as F
from sklearn.datasets import load_digits
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from fairlearn.metrics import demographic_parity_difference, equalized_odds_difference
torch.manual_seed(0); np.random.seed(0)
```

```
# ---- 1) Tezkor o'lchovlar ----
d = load_digits()
Xtr, Xte, ytr, yte = train_test_split(d.data / 16.0, d.target, test_size=0.3, random_state=0,
stratify=d.target)
Xtr, Xte, ytr, yte = map(torch.tensor, (Xtr.astype(np.float32), Xte.astype(np.float32), ytr,
yte))
# TODO 1: kichik MLP o'qiting; toza aniqlik va FGSM (eps=0.1) aniqligini o'lchang
# TODO 2: sintetik kredit ma'lumotida (A, income, history) LogisticRegression; DP va EO
farqlarini o'lchang
OLCHOV = {"toza_aniqlik": None, "fgsm_aniqlik_eps0.1": None, "dp_farqi": None, "eo_farqi":
None,
          "urug_belgilangan": True, "versiyalar_qayd": {"torch": torch.__version__}}

# ---- 2) Dalillar (talaba to'ldiradi) ----
DALIL = {
 1: ("ha", "model_card.md: maqsad — raqam tasnifi, foydalanuvchi — laboratoriya"),
 2: ("ha", "xavf toifasi: minimal (o'quv demo); kredit modeli bo'lsa — yuqori (AI Act III
ilova)"),
 3: ("ha", "sklearn digits (BSD litsenziya), sintetik kredit ma'lumoti (generator kodi)"),
 4: ("qisman", "sinflar vakilligi tekshirilgan, guruhlar bo'yicha yo'q"),
 5: ("ha", "sezgir atribut A, vakil belgi — income (korr. bilan)"),
 6: ("ha", "mezon: equalized odds — noto'g'ri rad etish zarari og'irroq"),
 10: ("ha", "gradient-saliency xaritasi (4-qadam)"),
 12: ("yo'q", ""), 13: ("qisman", "interfeysda AI haqida yozuv rejalashtirilgan"),
 14: ("yo'q", ""), 15: ("qisman", "drift monitoringi rejasi yozilgan, amalga oshirilmagan"),
 16: ("ha", "shaxsiy ma'lumot yo'q (ochiq to'plam)"), 17: ("qisman", "model card bor, datasheet
yo'q"),
 18: ("yo'q", ""), 19: ("qisman", "mas'ul shaxs ko'rsatilgan, shikoyat mexanizmi yo'q"),
}
BANDLAR = {1: "Maqsad va ta'sir ko'lami hujjatlashtirilgan", 2: "Xavf darajasi aniqlangan", 3:
"Ma'lumot manbai/litsenziyasi",
 4: "Guruhlar vakilligi tahlili", 5: "Sezgir atributlar va proxy aniqlangan", 6: "Adolatlilik
mezoni asoslangan",
 7: "Adolatlilik ko'rsatkichlari o'lchangan (chegara: EO<0.05)", 8: "Toza va adversarial
aniqlik o'lchangan",
 9: "Himoya chorasi sinovdan o'tgan (adv aniqlik >= 50%)", 10: "XAI tushuntirish mexanizmi
mavjud",
 11: "Tushuntirish ishonchliligi tekshirilgan", 12: "Inson nazorati nuqtalari", 13:
"Foydalanuvchi AI'ni biladi",
 14: "Audit izi (jurnal)", 15: "Drift/adolatlilik monitoringi", 16: "Shaxsiy ma'lumot
minimallashtirilgan",
 17: "Model card va datasheet", 18: "Nosozlik rejimi (fallback)", 19: "Mas'ul shaxs va shikoyat
mexanizmi",
 20: "Takrorlanuvchanlik (urug', versiyalar)"}

def baholash(n):
    """Har band uchun (holat, dalil) qaytaradi."""
    # TODO 3: texnik bandlar (7, 8, 9, 11, 20) — OLCHOV va band nomidagi chegaralar bo'yicha
avtomatik holat
    # TODO 4: qolganlari DALIL dan; dalilsiz "ha" -> "qisman"
    raise NotImplementedError("TODO 3-4: baholash")

BALL = {"ha": 5, "qisman": 2.5, "yo'q": 0}
print("=== Etik tekshiruv ro'yxati (ISO/IEC 42001, 23894, EU AI Act, NIST AI RMF) ===")
# TODO 5: 20 bandni baholab jadvalni chiqaring, jami ballni va bajarilmagan bandlarni yig'ing;
"Umumiy ball: .. / 100" va xulosa daraja
for n in range(1, 21):
    h, dl = baholash(n)
```

Natijada quyidagi satr(lar) chiqishi kerak: `=== Etik tekshiruv ro'yxati`, `Umumiy ball:`

TAJRIBA QILIB KO‘RING

- DALIL lug'atini o'z tizimingiz uchun to'ldiring va 80+ ballga chiqing — qaysi bandlar texnik ish talab qiladi?
- 9-band chegarasini qondirish uchun 3-qadamdagi adversarial o'qitishni skriptga qo'shing.
- Xavf toifasini (minimal/cheklangan/yuqori) kiritish parametri qiling va yuqori xavfda 12, 14, 18-bandlar «yo'q» bo'lsa umumiy xulosani «taqiqlanadi» deb chiqaring.

Mening natijam (o‘lchovlar, kuzatuvlar, xulosa):

Ilova. Ishoralar

Avval savolga o‘zingiz javob berishga harakat qiling; ishorani faqat qiynalganda o‘qing. To‘liq namuna yechim saytdagi virtual laboratoriyada bosqichni bajarganingizdan keyin ochiladi.

1. 1-qadam. Bazaviy model va FGSM: aniqlikning epsilon'ga bog'liqligi

1. data/16 — 1 kulrang daraja = 1/16. eps ning ma'nosi faqat shu fazoda aniq; eps×16 — necha kulrang darajaga teng.
2. Yo'qotishning kirish bo'yicha gradienti; sign(grad) har pikselni roppa-rosa ±eps ga suradi — L_inf sharining burchagi.
3. x ni nusxalab, grafikdan uzib, requires_grad_(True) qiling; torch.autograd.grad(loss, x) bilan oling.

```
grad, = torch.autograd.grad(loss, x)
```

4. .clamp(0, 1) — haqiqiy rasm bo'lib qolishi uchun; .detach() — keyingi hisoblarda eski grafik saqlanmasligi uchun.
5. torch.sign(torch.randn_like(Xte)) — tasodifiy yo'nalish. Hujum xavfi buzilish kattaligida emas, yo'nalishida.
6. Kutilgan: toza test ~0.97; eps=0.05 ~0.77, 0.1 ~0.3, 0.15 ~0.1; tasodifiy shovqin eps=0.15 da ~0.93. O'rtacha L_inf eps ga teng (yoki qirqish tufayli kichik).

Bajargach o‘ylang: Namunadagi FGSM bilan sizniki farq qiladimi (masalan, model.eval() yoki clamp joyi)? Egri chiziq nega bunchalik keskin tushadi — chiziqli model gipotezasi (Goodfellow) bilan tushuntiring.

2. 2-qadam. PGD hujumini qo'lda yozish va FGSM bilan taqqoslash

1. PGD — kichik alpha qadamli iterativ FGSM; har qadamda gradient yangidan hisoblanadi.
2. L_inf shariga proyeksiya — elementma-element x0−eps va x0+eps orasiga qirqish (torch.max/torch.min yoki clamp), so'ng [0,1].

```
xa = torch.min(torch.max(xa, x0 - eps), x0 + eps).clamp(0, 1)
```

3. eps-shar ichida bir tekis tasodifiy nuqtadan boshlash (torch.empty_like(x).uniform_(-eps, eps)) lokal tekis sohalardan qochishga yordam beradi.
4. Aks holda hisob grafigi qadamdan qadamga o'sib boradi va gradient eski nuqtalarga ham tarqaladi; xa.detach() + alpha * grad.sign().
5. (xa − Xte).abs().max() <= eps + 1e-6 — assert bilan; suzuvchi nuqta xatosi uchun kichik tolerantlik.
6. PGD har eps da FGSM dan past yoki teng; eps=0.15: FGSM ~0.11, PGD ~0.05; eps=0.2: PGD ~0.00. PGD kuchsiz chiqsa — eval()/detach/proyeksiyada xato.

Bajargach o‘ylang: PGD-10 va PGD-40 farqi qanchalik katta chiqdi va hisob narxi necha baravar oshdi? Namunadagi alpha = 2.5·eps/steps tanlovi nimaga xizmat qiladi — boshqa alpha bilan sinab ko'rdingizmi?

3. 3-qadam. Adversarial o'qitish (qisqa) va mustahkamlik murozasi

1. Madry: min_θ E[max_{||δ||∞≤eps} L(θ, x+δ, y)]. Ichki max — PGD hujumi, tashqi min — optimizator qadami.
2. Joriy model bilan: hujum har doim hozirgi zaif joylarni topishi kerak. Hujum paytida m.eval(), qadam paytida m.train().
3. PGD-k har qadamda k ta qo'shimcha forward+backward qiladi: taxminan (k+1) baravar. Vaqtni time.time() bilan o'lchang.
4. new_model() bir xil urug' bilan; baholashda torch.manual_seed(1) har hujumdan oldin; eps=0 da toza Xte.
5. Himoya faqat o'qitilgan chegaragacha kafolatlanadi; undan katta eps da aniqlik yana pasayadi.
6. Kutilgan: ~6x qimmat; PGD-10 eps=0.1 da ~0.27 -> ~0.83; eps=0.2 da ~0.2. Digits'da toza aniqlik deyarli tushmasligi mumkin.

Bajargach o‘ylang: Murozani o'z raqamlaringiz bilan tavsiflang: mustahkamlik qancha oshdi, narx qancha? Namuna bilan solishtirganda EPS_TRAIN yoki k ni o'zgartirish natijani qanday siljitdi?

4. 4-qadam. Gradient-saliency xaritasi: toza va hujum ostidagi raqamlar

1. Bashorat qilingan sinf logitining kirish x bo'yicha gradienti; ishorasi emas, moduli (|grad|) olinadi.
2. Ilg'or indekslash: model(x)[torch.arange(len(x)), cls]; logitlar yig'indisining x bo'yicha gradienti har namunaga alohida tushadi.

```
logit = model(x)[torch.arange(len(x)), cls].sum()
```

3. p = s / s.sum(1, keepdim=True); H = −Σ p log p (log(0) dan qochish uchun +1e-12). Katta H — tarqoq xarita.
4. np.corrcoef(a, b)[0, 1] — Pearson; ~0 bo'lsa xarita 'ko'chgan', ya'ni tushuntirish butunlay o'zgargan.
5. Biz modelning hozirgi qarorini tushuntiryapmiz; adv rasmda model boshqa sinfni tanlagan.
6. Kutilgan: rasmlar toza bilan deyarli bir xil, bashorat esa noto'g'ri; o'rtacha korrelyatsiya ~0 atrofida.

Bajargach o‘ylang: Entropiya adversarial namunani aniqlash belgisi bo'la oladimi — sizning jadvalingizda toza va adv entropiyalari aniq ajraladimi? Namunadagi xulosa bilan solishtiring.

5. 5-qadam. Adolatlilik: MetricFrame va ThresholdOptimizer

1. Yorliqlarda: A=1 guruhda haqiqiy ijobiylarning 25 % i 0 deb yozilgan. income A ga bog'liq — vakil (proxy) belgi.
2. DP — tanlov ulushi P(ŷ=1|A) farqi; EO — TPR va FPR farqlarining kattasi. Fairlearn'da demographic_parity_difference / equalized_odds_difference.
3. metrics= lug'at (nom -> funksiya), y_true, y_pred, sensitive_features; natija — mf.by_group.

```
mf = MetricFrame(metrics={"tanlov": selection_rate}, y_true=yte, y_pred=pred,
sensitive_features=Ate)
```

4. 'Bilmaslik orqali adolat' proxy belgilar tufayli ishlamaydi — income orqali A haqidagi axborot saqlanadi. feats = ['income', 'history', 'debt'].
5. Oldindan o'qitilgan modelning ehtimolliklari ustidan guruhga xos chegaralar tanlanadi: prefit=True, predict_method='predict_proba'; fit/predict da sensitive_features shart.
6. Kutilgan: baza DP ~0.25, EO ~0.27; A siz DP ~0.13; TO(DP) DP ~0.01, TO(EO) EO ~0.02; aniqlik 1-3 bandga pasayadi.

Bajargach o‘ylang: DP va EO ni bir vaqtda nolga tushira oldingizmi? Kredit masalasida qaysi mezon asosliroq — namunadagi xulosa va 7-qadamdagi DALIL[6] bilan solishtiring.

6. 6-qadam. SHAP TreeExplainer: global muhimlik, lokal izoh, additivlik

1. Barcha belgi koalitsiyalari bo'yicha o'rtacha marginal hissa; TreeSHAP daraxt tuzilmasidan foydalanib polinomial vaqtda aniq hisoblaydi.
2. Log-odds (decision_function). Ba'zi versiyalarda (n, 30, 2) qaytadi — unda 1-sinfni oling; expected_value ham massiv bo'lishi mumkin.

```
sv = sv[..., 1] if sv.ndim == 3 else sv
```

3. np.abs(sv).mean(0) — ijobiy va salbiy hissalar bir-birini yeyib qo'ymasligi uchun; pd.Series(..., index=X.columns).sort_values().
4. bazaviy qiymat + Σ SHAP = modelning shu namunadagi chiqishi; clf.decision_function(Xte.iloc[[i]]) bilan solishtiring.
5. Har namuna uchun top-5 (np.argsort(-np.abs(...))[:5]) to'plamlarining kesishmasi / 5, keyin o'rtacha.
6. Kutilgan: aniqlik ~0.94; top: worst perimeter, worst concave points, mean concave points; farq ~1e-15; barqarorlik ~0.99.

Bajargach o‘ylang: Sizning top-10 ro'yxatingiz namunadagi bilan bir xilmi? SHAP global muhimligi GradientBoosting'ning feature_importances_ dan nimasi bilan farq qiladi va qaysi biri ishonchliroq?

7. 7-qadam. Etik tekshiruv ro'yxatini avtomatik baholash

1. Texnik bandlar 7, 8, 9, 11, 20 — metrikalardan; qolganlari (inson nazorati, audit izi, fallback...) — DALIL lug'atidan.
2. Toza va FGSM eps=0.1 aniqligi (1-qadam), DP/EO farqi (5-qadam), urug' va versiyalar. Kichik MLP + FGSM + LogisticRegression yetarli.
3. 7-band: o'lchangan, lekin chegaradan o'tmasa — 'qisman'; 9-band: himoya sinovdan o'tmasa — 'yo'q'.

```
holat = "ha" if o["eo_farqi"] < 0.05 else "qisman"
```

4. Audit tamoyili: da'vo dalil bilan tasdiqlanadi. holat == 'ha' va dalil.strip() bo'sh bo'lsa -> 'qisman'; lug'atda yo'q band -> 'yo'q'.
5. ha=5, qisman=2.5, yo'q=0 (20 × 5 = 100). >= 70 yetarli, < 50 qoniqarsiz, oralig'i — qisman.
6. Kutilgan: ~60/100; bajarilmagan bandlar masalan 9, 12, 14, 18 — AI Act 9, 12, 14-moddalar (xavf boshqaruvi, jurnal, inson nazorati).

Bajargach o‘ylang: O'z tizimingiz uchun DALIL lug'atini to'ldirsangiz ball qanday o'zgaradi? Namunadagi baholash qoidalaridan qaysi biri juda yumshoq yoki juda qattiq ko'rinadi?

Qo‘shimcha mashqlar (10 ta, jami 100 ball)

№	Mashq	Daraja	Ball
1	**Epsilon to'rini kengaytirish** 1-qadam kodida epsilon to'rini 0 dan 0.3 gacha 0.01 qadam bilan kengaytiring, FGSM aniqligini har nuqtada o'lchang va aniqlik 50% dan pastga tushadigan eng kichik epsilon'ni (eps_50) toping. Grafik va eps_50 qiymati (kulrang darajalarda ham) hisobotga kiritiladi.	oson	5
2	**Guruhlar kesimida metrikalar** 5-qadam MetricFrame'iga `false_negative_rate` va `precision` metrikalarini qo'shing, to'rt variant uchun guruhlar jadvalini qayta chiqaring va «kredit» konteksti uchun qaysi metrika farqi eng muhim ekanini 3-4 jumla bilan asoslang.	oson	5
3	**SHAP lokal izohlar** 6-qadam kodida 3 ta namuna (bitta to'g'ri «xavfsiz», bitta to'g'ri «xavfli», bitta noto'g'ri bashorat) uchun top-5 SHAP hissalarini chiqaring, har biri uchun additivlikni tekshiring va noto'g'ri bashoratda qaysi belgilar modelni chalg'itganini izohlang.	oson	5
4	**Adversarial o'qitish radiusi** 3-qadam kodini EPS_TRAIN = 0.05, 0.1, 0.2 uchun ishga tushiring va har model uchun toza aniqlik hamda PGD-10 aniqligini eps = 0.05, 0.1, 0.15, 0.2 da o'lchang. 3x4 jadval va 3 egri chiziqli grafik tuzing; o'qitish radiusi kattalashganda toza aniqlik va kichik eps'dagi mustahkamlik qanday o'zgarishini tushuntiring.	o'rta	10
5	**Saliency asosida adversarial detektor** 4-qadam saliency funksiyasidan foydalanib, 200 toza va 200 PGD (eps=0.15) test namunasi uchun xarita entropiyasi va eng katta 5 piksel ulushini hisoblang. Shu ikki belgi bo'yicha oddiy chegara-detektor (yoki logistik regressiya) yasang, ROC-AUC ni (sklearn.metrics.roc_auc_score) o'lchang va ROC egri chizig'ini chizing.	o'rta	10
6	**In-processing tuzatish** 5-qadamga fairlearn.reductions.ExponentiatedGradient (EqualizedOdds, difference_bound=0.02) va GridSearch variantlarini qo'shing. Olti usul uchun aniqlik, DP farqi, EO farqi jadvalini tuzing, aniqlik-EO murozasini nuqtali grafikda ko'rsating va post- vs in-processing afzallik/kamchiliklarini (inferensda A kerakmi?) yozing.	o'rta	10
7	**Vakil belgilarni aniqlash** 5-qadam ma'lumotida har belgining sezgir atribut A bilan korrelyatsiyasini va A ni belgilar orqali bashorat qiluvchi yordamchi modelning AUC qiymatini hisoblang (proxy kuchi). So'ng 6-qadam SHAP yondashuvini 5-qadam modeliga (GradientBoosting) qo'llab, A olib tashlanganda ham A ta'siri qaysi belgi orqali o'tayotganini SHAP hissalari bilan ko'rsating.	o'rta	10
8	**Qora quti hujum: ko'chuvchanlik** Bir xil ma'lumotda ikki xil arxitekturali model (2-qadam MLP va kengroq/chuqurroq MLP yoki sklearn MLPClassifier) o'qiting. Birinchi modelga qarshi yasalgan FGSM va PGD namunalarini ikkinchisiga berib, ko'chuvchanlik (transfer) aniqligini 4 ta eps uchun o'lchang; oq quti natijasi bilan jadval va grafikda solishtiring va qora quti tahdid modeli uchun xulosa yozing.	qiyin	15

9	**Mos kelmaslik teoremasi amalda** 5-qadam generatorida bazaviy ulushlar farqini boshqaradigan parametr kiriting (A=1 uchun income siljishi 0, 0.4, 0.8, 1.2). Har holat uchun ThresholdOptimizer(DP) va ThresholdOptimizer(EO) ni qo'llab, DP farqi, EO farqi va guruhlar bo'yicha kalibrlash (bashorat ehtimoli bo'yicha haqiqiy ijobiy ulush, 5 ta bin) ni hisoblang. Bazaviy ulushlar farqi oshganda uchala mezonni bir vaqtda qondirib bo'lmasligini jadval va grafik bilan ko'rsating.	qiyin	15
10	**To'liq ishonchlilik hisoboti generatori** 7-qadam skriptini kengaytiring: u 1-6 qadam funksiyalarini chaqirib toza/FGSM/PGD aniqligini (3 eps), adversarial o'qitilgan modelni, DP/EO farqlarini (baza va tuzatilgan), SHAP top-5 va saliency korrelyatsiyasini o'lchasin, so'ng 20 bandni dalillar bilan to'ldirib Markdown formatida model kartasi + tekshiruv ro'yxati hisobotini print qilsin. Xavf toifasi (minimal/yuqori) kirish parametri bo'lsin; yuqori xavfda majburiy bandlar bajarilmasa «joriy etish mumkin emas» xulosasi chiqsin. Umumiy ish vaqti 60 s dan oshmasin.	qiyin	15

Mustaqil topshiriqlar — 20 ta variant

Variant jurnal raqami bo‘yicha tanlanadi (20 dan katta bo‘lsa — 20 ga bo‘lgandagi qoldiq, 0 → 20). Laboratoriya bosqichlari kodini asos qilib, o‘z variantingiz parametrlari bilan bajaring.

1-variant. Mikrokredit: hudud bo'yicha adolatlilik va raqamli imzo rasmlariga FGSM oson

Soha: Moliya (mikrokredit)

Mikromoliya tashkiloti arizachilarning skanerlangan raqamli kodlarini (digits) avtomatik o'qiydi va alohida model bilan kredit berish qarorini chiqaradi. Sezgir atribut — hudud (qishloq = 1, shahar = 0); tarixiy ma'lumotda qishloq arizachilarining to'lovga qodir qismi 20 % hollarda noto'g'ri rad etilgan. Sizdan raqam o'qiydigan modelga FGSM/PGD hujumi, qisqa adversarial o'qitish, saliency, kredit modelida DP mezoni bo'yicha tuzatish, SHAP tushuntirish va etik ro'yxatni to'ldirish talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf, [0,1] piksel
Epsilon to'ri	0, 0.02, 0.04, 0.06, 0.08, 0.1, 0.12
PGD	7 qadam, alpha = 2.5*eps/7, tasodifiy boshlanish
EPS_TRAIN	0.06
Sezgir atribut	hudud (A=1 qishloq, ulushi 0.45)
Tarafkashlik	A=1 ijobiylarining 20 % noto'g'ri rad (yorliq flip)
Vakil belgi	oylik daromad = N(4.8 - 0.6*A, 1)
Adolatlilik mezoni	demographic parity

QADAMLAR

1. s1 kodini variant epsilon to'ri bilan ishga tushiring; FGSM aniqlik jadvali (eps, eps*16 daraja, aniqlik) va tasodifiy shovqin bilan taqqoslash eps=0.08 da; aniqlik 50 % dan tushadigan eps_50 ni toping.
2. s2 kodida PGD-7 va PGD-20 ni FGSM bilan shu to'rda solishtiring; L_inf assert o'tsin; 3 egri chiziqli grafik.
3. s3 adversarial o'qitishni EPS_TRAIN=0.06, k=5 bilan bajaring; toza vs adversarial model jadvali (eps = 0, 0.04, 0.08, 0.12) va o'qitish vaqti nisbati.
4. s4 saliency panelini 8 ta raqam uchun eps=0.08 PGD bilan chizing; o'rtacha korrelyatsiya va entropiyani yozing.
5. s5 generatorini variant parametrlariga (ulush 0.45, flip 0.2, daromad siljishi 0.6) moslang; baza, unawareness, ThresholdOptimizer(DP) va (EO) uchun aniqlik, DP farqi, EO farqi jadvali; DP nega tanlanganini izohlang.
6. s6 SHAP'ni kredit ma'lumotida o'qitilgan GradientBoosting (A'siz belgilar) uchun bajaring: global top-3, bitta rad etilgan arizachi uchun lokal izoh, additivlik tekshiruvi.
7. s7 ro'yxatini mikrokredit tizimi uchun to'ldiring (xavf toifasi: yuqori), umumiy ball va bajarilmagan majburiy bandlar.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli,

beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

2-variant. Ishga qabul: rezyume skoringi — jins bo'yicha EO va hujjat rasmlariga PGD oson

Soha: Bandlik (ishga qabul)

HR-platforma nomzodlar yuklagan hujjatlardagi raqamli maydonlarni (digits) o'qiydi va alohida skoring modeli suhbatga taklif qilish qarorini chiqaradi. Sezgir atribut — jins (A=1 ayollar, ulushi 0.35); tarixiy ma'lumotda ayol nomzodlarning muvaffaqiyatli qismi 15 % hollarda rad etilgan, qo'shimcha ravishda vakil belgi sifatida 'ish tajribasi yillari' A bilan bog'liq. Sizdan hujjat o'quvchi modelga hujum tahlili va skoring modelida equalized odds bo'yicha tuzatish talab qilinadi.

Rasm ma'lumoti	sklearn digits, faqat 0-4 sinflar (5 sinf)
Epsilon to'ri	0, 0.03, 0.06, 0.1, 0.15, 0.2
PGD	10 va 30 qadam, alpha = 2*eps/qadam
EPS_TRAIN	0.1
Sezgir atribut	jins (A=1 ulushi 0.35)
Tarafkashlik	A=1 ijobiylarining 15 % flip
Vakil belgi	tajriba = N(6 - 1.2*A, 2)
Adolatlilik mezoni	equalized odds

QADAMLAR

1. s1 kodini 0-4 sinflarga cheklang (maska bilan), chiqish qatlami 5 ta; FGSM aniqlik jadvali variant to'rida; 5 sinfli masala 10 sinfliga qaraganda chidamliroqmi — izohlang.
2. s2 PGD-10 va PGD-30 (alpha = 2*eps/qadam) vs FGSM; L_inf assert; grafik.
3. s3 adversarial o'qitish EPS_TRAIN=0.1; toza/adversarial jadval; muroza qiymatlari.
4. s4 saliency: eps=0.1 PGD; 8 ta namuna paneli, korrelyatsiya o'rtachasi.
5. s5 generatori: jins ulushi 0.35, flip 0.15, tajriba belgisi A bilan bog'liq; MetricFrame'ga false_negative_rate qo'shing; 4 usul jadvali; EO nega ishga qabul uchun mos — 3 jumla.
6. s6 SHAP (GradientBoosting, skoring ma'lumoti): tajriba belgisi A ta'sirini qanday o'tkazayotganini SHAP bilan ko'rsating; additivlik.
7. s7 ro'yxati: ishga qabul = yuqori xavf (AI Act III ilova); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

3-variant. Tibbiy triaj: shoshilinch yordam ustuvorligi — yosh guruhi va o'lchov tarafkashligi oson

Soha: Tibbiyot (triaj)

Shoshilinch yordam bo'limi bemorlarni 'shoshilinch / kutishi mumkin' sinfiga ajratuvchi model va analizator ko'rsatkichlarini rasmdan o'qiydigan OCR moduli ishlatadi. Sezgir atribut — yosh guruhi (A=1: 65 yoshdan katta, ulushi 0.3); tarafkashlik yorliqda emas, o'lchovda: keksa bemorlarda asosiy belgi (simptom bali) ko'proq shovqin bilan yozilgan. Sizdan noto'g'ri 'kutishi mumkin' (FN) zarari og'ir bo'lgani uchun TPR tengligi mezonini tekshirish talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.01, 0.03, 0.05, 0.08, 0.12
PGD	10 qadam, tasodifiy boshlanish bilan va boshlanishsiz
EPS_TRAIN	0.05
Sezgir atribut	yosh guruhi (A=1 ulushi 0.30)
Tarafkashlik	o'lchov shovqini: simptom bali A=1 da N(0, 1.8), A=0 da N(0, 0.6)
Adolatlilik mezoni	true positive rate parity (fairlearn: true_positive_rate_parity)
SHAP ma'lumoti	breast_cancer, GradientBoosting

QADAMLAR

1. s1 FGSM jadvali variant to'rida; kichik eps (0.01, 0.03) da aniqlik pasayishini kulrang darajalarda izohlang.
2. s2 PGD-10 tasodifiy boshlanish bilan/siz vs FGSM; assert; grafik; boshlanish ta'siri 2 jumla.
3. s3 adversarial o'qitish EPS_TRAIN=0.05; jadval; eps=0.12 da himoya zaiflashishini ko'rsating.
4. s4 saliency eps=0.08; korrelyatsiya va entropiya; entropiya detektor belgisi bo'la oladimi — izoh.
5. s5 generatorini o'zgartiring: yorliq flip yo'q, A=1 guruhda simptom bali shovqini kattaroq; baza, unawareness, ThresholdOptimizer(true_positive_rate_parity) va (equalized_odds) uchun aniqlik, TPR farqi, FNR farqi jadvali.
6. s6 SHAP'ni breast_cancer GradientBoosting uchun bajaring: top-10, bitta 'xavfli' namuna lokal izohi, additivlik, 1 % shovqin barqarorligi.
7. s7 ro'yxati triaj tizimi uchun (yuqori xavf, 12 va 18-bandlar majburiy): ball, xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

4-variant. Ta'lim: stipendiya tanlovi — maktab turi bo'yicha DP va imtihon varaqlari OCR hujumi oson

Soha: Ta'lim

Universitet stipendiya komissiyasi imtihon varaqlaridagi raqamlarni OCR bilan o'qiydi va alohida model stipendiyaga tavsiya qiladi. Sezgir atribut — maktab turi (A=1 qishloq maktabi, ulushi 0.5); tarixiy qarorlarda qishloq maktabi bitiruvchilarining munosib qismi 30 % hollarda rad etilgan, vakil belgi — 'ingliz tili sertifikati bali'. Sizdan OCR modelining mustahkamligini va stipendiya modelida DP tuzatishini baholash talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf, model MLP 64-96-10 (bitta yashirin qatlam)
Epsilon to'ri	0, 0.05, 0.1, 0.15, 0.2, 0.25, 0.3
PGD	10 va 40 qadam
EPS_TRAIN	0.15
Sezgir atribut	maktab turi (A=1 ulushi 0.50)
Tarafkashlik	A=1 ijobiylarining 30 % flip
Vakil belgi	ingliz tili bali = N(60 - 12*A, 15)
Adolatlilik mezoni	demographic parity

QADAMLAR

1. s1 modelini bitta yashirin qatlamli (64-96-10) qiling; FGSM jadvali variant to'rida; chuqurroq lab modeli bilan eps=0.1 da solishtiring.
2. s2 PGD-10 va PGD-40 vs FGSM; assert; grafik.
3. s3 EPS_TRAIN=0.15 bilan adversarial o'qitish; toza aniqlik qancha tushdi; eps=0.05 da himoya.
4. s4 saliency eps=0.15; panel; korrelyatsiya.
5. s5 generatori: ulush 0.5, flip 0.3, ingliz tili bali vakil belgi; 4 usul jadvali; MetricFrame'ga precision qo'shing; DP tanlovini 3 jumla bilan asoslang.
6. s6 SHAP (stipendiya ma'lumoti, GradientBoosting): ingliz tili bali hissasi guruhlar bo'yicha o'rtacha qanday farq qiladi; additivlik.
7. s7 ro'yxati ta'lim tizimi uchun (yuqori xavf: ta'limga kirish); ball va tavsiyalar.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

5-variant. Avto sug'urta: narxlash skoringi — yosh guruhi va haqiqiy bazaviy farq

oson

Soha: Sug'urta

Sug'urta kompaniyasi avto polis uchun 'yuqori xavfli haydovchi' bashoratini qiladi va haydovchilik guvohnomasi raqamlarini rasmdan o'qiydi. Sezgir atribut — yosh (A=1: 25 yoshgacha, ulushi 0.25). Bu variantda yorliq flip yo'q: guruhlar orasida haqiqiy bazaviy ulush farqi bor (yoshlarda hodisalar ko'proq), shuning uchun DP va EO bir vaqtda qondirilmaydi. Sizdan hujum tahlili bilan birga qaysi mezon sug'urta uchun to'g'ri ekanini raqamlar bilan asoslash talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.02, 0.05, 0.08, 0.1, 0.15
PGD	10 qadam, alpha = 3*eps/10
EPS_TRAIN	0.08
Sezgir atribut	yosh guruhi (A=1 ulushi 0.25)
Tarafkashlik	flip 0; bazaviy farq: xavf bali = 0.9*staj + 0.7*A + shovqin
Adolatlilik mezoni	equalized odds vs demographic parity (taqqoslash)
SHAP ma'lumoti	sug'urta sintetik, GradientBoosting

QADAMLAR

1. s1 FGSM jadvali; tasodifiy shovqin taqqoslash eps=0.1.
2. s2 PGD-10 (alpha = 3*eps/10) vs FGSM; alpha kattaligining ta'siri haqida izoh; assert; grafik.
3. s3 EPS_TRAIN=0.08 adversarial o'qitish; jadval; vaqt nisbati.
4. s4 saliency eps=0.1; panel; korrelyatsiya.
5. s5 generatorini o'zgartiring: flip yo'q, A to'g'ridan-to'g'ri xavfga ta'sir qiladi (haqiqiy bazaviy farq); 4 usul jadvali; ThresholdOptimizer(DP) aniqlikni qancha tushiradi va EO nega sug'urta uchun ma'qulroq — asoslang.
6. s6 SHAP (GradientBoosting, sug'urta ma'lumoti, A'siz): staj belgisining hissasi; bitta yosh haydovchi uchun lokal izoh; additivlik.
7. s7 ro'yxati (sug'urta narxlash: yuqori xavf AI Act bo'yicha); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

6-variant. Reklama: ish e'lonlarini ko'rsatish — jins bo'yicha tanlov ulushi va banner raqamlariga hujum oson

Soha: Reklama (marketing)

Reklama platformasi foydalanuvchiga yuqori maoshli ish e'lonini ko'rsatish-ko'rsatmaslikni bashorat qiladi va bannerlardagi raqamli kodlarni rasmdan tekshiradi. Sezgir atribut — jins (A=1 ulushi 0.5); tarixiy bosish (click) yorlig'ida ayollar uchun ijobiy natijalar 25 % kam qayd etilgan, vakil belgi — 'ko'rilgan toifalar' soni. Sizdan tanlov ulushi (selection rate) farqini o'lchash va DP tuzatishi reklama samaradorligiga ta'sirini baholash talab qilinadi.

Rasm ma'lumoti	sklearn digits, juft/toq (2 sinf)
Epsilon to'ri	0, 0.05, 0.1, 0.15, 0.2, 0.3
PGD	10 qadam
EPS_TRAIN	0.1
Sezgir atribut	jins (A=1 ulushi 0.50)
Tarafkashlik	A=1 ijobiylarining 25 % flip
Vakil belgi	toifalar soni = Poisson(7 - 2*A)
Adolatlilik mezoni	demographic parity (selection rate)

QADAMLAR

1. s1 modelini 2 sinfli (juft/toq) qiling; FGSM jadvali; 2 sinfli masalada tasodifiy taxmin 50 % ekanini hisobga olib eps_50 o'rniga eps_75 ni toping.
2. s2 PGD-10 vs FGSM; assert; grafik.
3. s3 EPS_TRAIN=0.1 adversarial o'qitish; jadval; muroza.
4. s4 saliency eps=0.15, 8 ta namuna; korrelyatsiya.
5. s5 generatori: ulush 0.5, flip 0.25, Poisson vakil belgi; MetricFrame: selection_rate, TPR, FPR; 4 usul; DP tuzatishdan keyin umumiy tanlov ulushi va aniqlik qanday o'zgardi.
6. s6 SHAP (reklama ma'lumoti, GradientBoosting): toifalar soni belgisi hissasi; beeswarm; additivlik.
7. s7 ro'yxati (reklama: cheklangan xavf, lekin bandlikka ta'sir bo'lsa yuqori); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

7-variant. Telekom: chegirma taklifi modeli — til/hudud bo'yicha adolatlilik va SIM-karta raqamlari OCR oson

Soha: Telekom

Mobil operator ketish ehtimoli yuqori abonentlarga chegirma taklif qiladi; SIM-karta raqamlari rasmdan o'qiladi. Sezgir atribut — xizmat tili/hudud (A=1 ulushi 0.4); tarixda A=1 guruhdagi 'saqlab qolinadigan' abonentlarning 18 % noto'g'ri belgilangan, vakil belgi — 'oylik to'lov'. Sizdan OCR mustahkamligi va chegirma modelida EO tuzatishini baholash hamda wine ma'lumotida SHAP tushuntirish talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf, o'qitish 150 qadam (kam o'qitilgan model)
Epsilon to'ri	0, 0.02, 0.05, 0.1, 0.15, 0.2
PGD	10 qadam
EPS_TRAIN	0.1, k = 3
Sezgir atribut	til/hudud (A=1 ulushi 0.40)
Tarafkashlik	A=1 ijobiylarining 18 % flip
Vakil belgi	oylik to'lov = N(5.2 - 0.9*A, 1.2)
SHAP ma'lumoti	sklearn wine (3 sinf), GradientBoosting

QADAMLAR

1. s1 modelini 150 qadam o'qiting; FGSM jadvali; 300 qadamli model bilan eps=0.1 da solishtiring (kam o'qitilgan model chidamliroqmi?).
2. s2 PGD-10 vs FGSM; assert; grafik.
3. s3 EPS_TRAIN=0.1, k=3 adversarial o'qitish; k=5 bilan vaqt va mustahkamlikni solishtiring.
4. s4 saliency eps=0.15; panel; korrelyatsiya.
5. s5 generatori: ulush 0.4, flip 0.18, oylik to'lov vakil belgi; 4 usul jadvali; EO tanlovini asoslang.
6. s6 SHAP'ni wine (3 sinf) GradientBoosting uchun bajaring: sinf bo'yicha SHAP massivini to'g'ri tanlang, top-5, additivlik ko'p sinfli holatda.
7. s7 ro'yxati (telekom chegirma: cheklangan xavf); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

8-variant. Jamoat xavfsizligi: tekshiruv ustuvorligi modeli — hudud bo'yicha FPR tengligi va fikr-mulohaza halqasi o'rta

Soha: Xavfsizlik (jamoat tartibi)

Shahar xavfsizlik xizmati qaysi murojaatlarni birinchi tekshirishni bashorat qiluvchi model va hujjat raqamlarini o'qiydigan OCR ishlatadi. Sezgir atribut — hudud (A=1 ulushi 0.35); tarafkashlik fikr-mulohaza halqasi ko'rinishida: A=1 hududda tekshiruvlar ko'proq o'tkazilgani uchun 'ijobiy' yorliqlar 1.6 baravar ko'p qayd etilgan (haqiqiy xavf teng). Noto'g'ri tekshiruv (FP) zarari og'ir, shuning uchun FPR tengligi asosiy mezon.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.02, 0.05, 0.1, 0.15
PGD	10 va 40 qadam; qo'shimcha L_2 PGD (eps_2 = 1.0, 2.0)
EPS_TRAIN	0.1
Sezgir atribut	hudud (A=1 ulushi 0.35)
Tarafkashlik	A=1 guruhda haqiqiy salbiylarning 20 % 'ijobiy' deb yozilgan (ortiqcha nazorat)
Adolatlilik mezoni	false positive rate parity
SHAP ma'lumoti	xavfsizlik sintetik, GradientBoosting

QADAMLAR

1. s1 FGSM jadvali variant to'rida.
2. s2 PGD-10, PGD-40 vs FGSM (L_inf) va qo'shimcha L_2 PGD (gradientni normalashtirib, eps_2 radiusli sharga proyeksiya) eps_2 = 1.0, 2.0; ikkala tahdid modelini bitta jadvalda.
3. s3 adversarial o'qitish EPS_TRAIN=0.1; L_inf'ga o'qitilgan model L_2 hujumga qanchalik chidamli — jadval.
4. s4 saliency eps=0.1; panel; korrelyatsiya va entropiya.
5. s5 generatorini o'zgartiring: A=1 guruhda salbiylarning 20 % ijobiy deb flip (ortiqcha nazorat); MetricFrame: FPR, FNR, selection_rate; baza, unawareness, ThresholdOptimizer(false_positive_rate_parity), (equalized_odds); FPR farqi va aniqlik jadvali.
6. Fikr-mulohaza halqasi simulyatsiyasi: tuzatilmagan model bashoratlarini 3 'yil' davomida yangi yorliq sifatida qayta o'qiting va FPR farqi qanday o'sishini grafikda ko'rsating; tuzatilgan model bilan takrorlang.
7. s6 SHAP (sintetik, GradientBoosting): A olib tashlanganda ham qaysi belgi hudud ta'sirini o'tkazadi; s7 ro'yxati (yuqori xavf, huquqni muhofaza qilish — AI Act III ilova): ball, majburiy bandlar.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

9-variant. Uy-joy ijarasi: ijarachini tanlash platformasi — oilaviy holat va vakil belgilar o'rta

Soha: Uy-joy (ijara platformasi)

Onlayn ijara platformasi uy egalariga ijarachi arizasini 'tavsiya / tavsiya emas' deb baholaydi va pasport raqamlarini rasmdan o'qiydi. Sezgir atribut — bolalar bilan oila (A=1 ulushi 0.3); tarixiy rad etishlarda A=1 guruhning to'lovga qodir qismi 22 % flip qilingan, ikkita vakil belgi bor: 'oila a'zolari soni' va 'kerakli xonalar soni'. Sizdan vakil belgilar kuchini o'lchash (A ni bashorat qiluvchi yordamchi model AUC) va DP tuzatish talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.03, 0.06, 0.1, 0.15, 0.2
PGD	10 qadam, alpha = 2.5*eps/10
EPS_TRAIN	0.08
Sezgir atribut	bolalar bilan oila (A=1 ulushi 0.30)
Tarafkashlik	A=1 ijobiylarining 22 % flip
Vakil belgilar	oila a'zolari = Poisson(2 + 2*A), xonalar = 1 + a'zolar/2 + shovqin
Adolatlilik mezoni	demographic parity; proxy kuchi: A ni belgilar orqali bashorat qiluvchi LogisticRegression AUC

QADAMLAR

1. s1 FGSM jadvali; s2 PGD-10 vs FGSM; assert; grafik (ikkala qadam bitta skriptda).
2. s3 adversarial o'qitish EPS_TRAIN=0.08; jadval; muroza.
3. s4 saliency eps=0.1; panel; SmoothGrad (10 shovqinli nusxa) bilan korrelyatsiya qanday o'zgaradi.
4. s5 generatori: ikki vakil belgi; har belgining A bilan korrelyatsiyasi va A ni bashorat qiluvchi yordamchi model AUC (proxy kuchi) jadvali.
5. 4 usul jadvali (baza, unawareness, ThresholdOptimizer DP va EO); vakil belgilarni ham olib tashlagan 5-usulni qo'shing: aniqlik va DP farqi.
6. s6 SHAP (ijara ma'lumoti, GradientBoosting, A'siz): oila a'zolari va xonalar hissasi A=0/A=1 guruhlarda o'rtacha; additivlik.
7. s7 ro'yxati (uy-joyga kirish: yuqori xavf); ball va xulosa — vakil belgilar bilan nima qilish kerak.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

10-variant. Universitetga qabul: kirish ballari modeli — maktab tili va test balining vakilligi o'rta

Soha: Ta'lim (qabul)

Universitet qabul komissiyasi abituriyentning birinchi kursni muvaffaqiyatli tugatish ehtimolini bashorat qiladi va test varaqlaridagi raqamlarni OCR bilan o'qiydi. Sezgir atribut — maktab ta'lim tili (A=1 ulushi 0.4); tarafkashlik ikki qatlamli: test bali A=1 uchun o'rtacha 8 ballga past o'lchangan (o'lchov tarafkashligi), yorliq flip 10 %. Sizdan EO tuzatish, in-processing (ExponentiatedGradient) qo'shish va OCR modeliga qora quti hujumni baholash talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf; ikkinchi model sklearn MLPClassifier (qora quti)
Epsilon to'ri	0, 0.05, 0.1, 0.15, 0.2
PGD	10 qadam
EPS_TRAIN	0.1
Sezgir atribut	maktab tili (A=1 ulushi 0.40)
Tarafkashlik	test bali = haqiqiy - 8*A + N(0, 5); flip 10 %
Adolatlilik mezoni	equalized odds; in-processing ExponentiatedGradient(EqualizedOdds, difference_bound=0.02)
SHAP ma'lumoti	qabul sintetik, GradientBoosting

QADAMLAR

1. s1 FGSM va s2 PGD-10 jadvallari; assert; grafik.
2. Ko'chuvchanlik: PyTorch MLP uchun yasalgan FGSM/PGD namunalarini sklearn MLPClassifier (hidden 100, 64 belgi) ga bering; 4 eps uchun transfer aniqligi jadvali va oq quti bilan taqqoslash.
3. s3 adversarial o'qitish EPS_TRAIN=0.1; adversarial model uchun transfer hujum qanchalik ishlaydi.
4. s4 saliency eps=0.1; panel; korrelyatsiya.
5. s5 generatori: o'lchov tarafkashligi (test bali - 8*A) + flip 0.1; baza, unawareness, ThresholdOptimizer(EO), ExponentiatedGradient(EO, 0.02) — 4 usul; aniqlik-EO muroza nuqtali grafigi.
6. s6 SHAP (GradientBoosting, qabul ma'lumoti): test bali hissasi A guruhlari bo'yicha; additivlik; shovqin barqarorligi.
7. s7 ro'yxati (ta'limga kirish: yuqori xavf); ball va xulosa — o'lchov tarafkashligini qaysi bosqichda tuzatish kerak (ma'lumot yoki model).

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

11-variant. Sog'liq sug'urtasi: xarajat prognozi — surunkali kasallik guruhi va regressiya SHAP o'rta

Soha: Sug'urta (tibbiy)

Tibbiy sug'urta kompaniyasi mijozning yillik xarajatini bashorat qiladi va retsept raqamlarini rasmdan o'qiydi. Sezgir atribut — surunkali kasallik mavjudligi (A=1 ulushi 0.2); kompaniya 'yuqori xarajat' sinfini chegara bilan aniqlaydi va A=1 guruhda tarixiy yorliqlar 20 % ortiqcha 'yuqori' deb belgilangan. Sizdan tasniflash adolatliligi bilan birga diabetes regressiya ma'lumotida SHAP tushuntirish (TreeExplainer, GradientBoostingRegressor) talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.02, 0.04, 0.08, 0.12, 0.16
PGD	10 qadam; 20 qadam
EPS_TRAIN	0.08
Sezgir atribut	surunkali kasallik (A=1 ulushi 0.20)
Tarafkashlik	A=1 salbiylarining 20 % 'yuqori xarajat' deb flip
Adolatlilik mezoni	equalized odds, FPR farqiga alohida e'tibor
SHAP ma'lumoti	sklearn diabetes (regressiya), GradientBoostingRegressor

QADAMLAR

1. s1 FGSM va s2 PGD-10/PGD-20 jadvallari; assert; grafik.
2. s3 adversarial o'qitish EPS_TRAIN=0.08; jadval; k=1 (FGSM-AT) bilan 'katastrofik overfitting' bor-yo'qligini tekshiring.
3. s4 saliency eps=0.08; panel; eng muhim 8 pikselni 0 qilib (deletion) bashorat ehtimoli qanchaga tushishini o'lchang.
4. s5 generatori: A=1 salbiylarining 20 % ijobiy flip; MetricFrame: FPR, FNR, selection_rate; baza, unawareness, ThresholdOptimizer(EO), (DP); FPR farqi jadvali.
5. s6 SHAP'ni diabetes GradientBoostingRegressor uchun bajaring: expected_value + sum(SHAP) = predict (additivlik), top-5 belgilar, bitta bemor uchun lokal izoh, dependence plot (bmi).
6. Barqarorlik: 1 % va 5 % shovqinda top-5 mosligi; regressiya SHAP'da qiymatlar birligi (xarajat birligida) haqida izoh.
7. s7 ro'yxati (tibbiy sug'urta: yuqori xavf); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi

asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

12-variant. E-tijorat: to'lov firibgarligi detektori — mamlakat/hudud bo'yicha FPR va nomutanosib sinflar o'rta

Soha: E-tijorat (to'lovlar)

To'lov shlyuzi tranzaksiyani 'firibgarlik' deb bloklash qarorini chiqaradi va karta raqamlarini rasmdan o'qiydi. Sezgir atribut — hudud (A=1 ulushi 0.3); firibgarlik 4 % (nomutanosib), A=1 hududda tarixiy bloklash qoidalari tufayli salbiylarning 12 % 'firibgarlik' deb yozilgan. Halol mijozni bloklash (FP) biznesga zarar, shuning uchun FPR tengligi asosiy; sizdan nomutanosib sinflarda MetricFrame bilan to'g'ri o'lchash va chegara tanlash talab qilinadi.

Rasm ma'lumoti	sklearn digits, faqat 1 vs 7 (2 sinf, chalkash juftlik)
Epsilon to'ri	0, 0.03, 0.06, 0.1, 0.15, 0.2
PGD	10 qadam; yo'naltirilgan (targeted) FGSM 1 -> 7
EPS_TRAIN	0.1
Sezgir atribut	hudud (A=1 ulushi 0.30)
Tarafkashlik	ijobiy ulush 4 %; A=1 salbiylarining 12 % flip
Adolatlilik mezoni	false positive rate parity
SHAP ma'lumoti	firibgarlik sintetik, GradientBoosting (class_weight o'rniga sample_weight)

QADAMLAR

1. s1 modelini 1 vs 7 ikki sinfli qiling; FGSM jadvali; yo'naltirilgan FGSM (1 -> 7, gradientni maqsad sinf yo'qotishi bo'yicha teskari) muvaffaqiyat ulushi eps bo'yicha.
2. s2 PGD-10 vs FGSM; assert; grafik.
3. s3 adversarial o'qitish EPS_TRAIN=0.1; jadval.
4. s4 saliency eps=0.1 uchun 1 va 7 rasmlari; qaysi piksellar hal qiluvchi; korrelyatsiya.
5. s5 generatori: ijobiy ulush 4 % (chegara bilan), A=1 salbiylarining 12 % flip; LogisticRegression(class_weight='balanced'); MetricFrame: FPR, TPR, precision, selection_rate; baza, unawareness, ThresholdOptimizer(false_positive_rate_parity), (equalized_odds).
6. Nomutanosiblik ta'siri: umumiy aniqlik 96 % bo'lsa ham FPR farqi katta bo'lishi mumkinligini ko'rsating; balanced accuracy qo'shing; s6 SHAP (GradientBoosting, sample_weight) top-5 va additivlik.
7. s7 ro'yxati (to'lov bloklash: yuqori xavf — moliyaviy xizmatlarga kirish); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi

asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

13-variant. Ijtimoiy himoya: subsidiya ustuvorligi — oila kattaligi/hudud va kalibrlash o'rta

Soha: Davlat xizmatlari

Ijtimoiy himoya agentligi oilalarni subsidiya uchun 'ustuvor' deb belgilaydi va arizadagi raqamlarni OCR bilan o'qiydi. Sezgir atribut — hudud (A=1 ulushi 0.55, ko'pchilik guruh); tarixiy ro'yxatlarda A=1 hududning muhtoj oilalari 28 % hollarda ro'yxatga kiritilmagan, vakil belgi — 'kommunal to'lov qarzi'. Agentlik ehtimollik bahosiga tayanadi, shuning uchun guruhlar bo'yicha kalibrlash ham tekshiriladi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.02, 0.05, 0.1, 0.15, 0.2, 0.3
PGD	10 qadam
EPS_TRAIN	0.1
Sezgir atribut	hudud (A=1 ulushi 0.55)
Tarafkashlik	A=1 ijobiylarining 28 % flip; vakil belgi: kommunal qarz = N(2 + 1.1*A, 1)
Adolatlilik mezoni	demographic parity + guruhlar bo'yicha kalibrlash (5 bin)
SHAP ma'lumoti	subsidiya sintetik, GradientBoosting

QADAMLAR

1. s1 FGSM va s2 PGD-10 jadvallari; assert; grafik.
2. s3 adversarial o'qitish EPS_TRAIN=0.1; jadval; muroza.
3. s4 saliency eps=0.15; panel; korrelyatsiya va entropiya; adversarial o'qitilgan model uchun xaritalar korrelyatsiyasi yuqoriroqmi.
4. s5 generatori: ulush 0.55, flip 0.28, kommunal qarz vakil belgi; 4 usul jadvali (aniqlik, DP, EO).
5. Kalibrlash: har usul uchun predict_proba bo'yicha 5 bin, har binda haqiqiy ijobiy ulush A=0/A=1 uchun; kalibrlash egri chiziqlari; ThresholdOptimizer kalibrlashni buzadimi.
6. s6 SHAP (GradientBoosting, A'siz): kommunal qarz hissasi; bitta rad etilgan oila uchun lokal izoh (fuqaroga tushunarli tilda yozib bering); additivlik.
7. s7 ro'yxati (davlat xizmatlariga kirish: yuqori xavf; 13, 19-bandlar muhim); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

14-variant. Taksi platformasi: haydovchi reytingi va buyurtma taqsimoti — jins/yosh kesishmasi o'rta

Soha: Transport (platforma)

Taksi platformasi haydovchiga 'premium buyurtma' berish qarorini modellashtiradi va avtomobil raqamlarini rasmdan o'qiydi. Ikki sezgir atribut: jins (A1, ulushi 0.2) va yosh guruhi 50+ (A2, ulushi 0.25); tarafkashlik faqat kesishmada — A1=1 va A2=1 bo'lgan haydovchilarning munosib qismi 35 % flip. Sizdan MetricFrame'da kesishgan guruhlar (4 ta) bo'yicha tahlil, ThresholdOptimizer'ni birlashgan atribut bilan qo'llash va avtomobil raqami OCR mustahkamligi talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.04, 0.08, 0.12, 0.16, 0.2
PGD	10 qadam, alpha = 2.5*eps/10
EPS_TRAIN	0.12
Sezgir atributlar	jins A1 (ulushi 0.20), yosh 50+ A2 (ulushi 0.25) — kesishma 4 guruh
Tarafkashlik	faqat A1=1 va A2=1 kesishmada ijobiylarning 35 % flip
Vakil belgi	o'rtacha reyting = N(4.6 - 0.15*A1 - 0.1*A2, 0.2)
Adolatlilik mezoni	equalized odds (kesishgan guruhlar)

QADAMLAR

1. s1 FGSM va s2 PGD-10 jadvallari; assert; grafik.
2. s3 adversarial o'qitish EPS_TRAIN=0.12; jadval; muroza.
3. s4 saliency eps=0.12; panel; korrelyatsiya.
4. s5 generatorini ikki atributli qiling; MetricFrame'ni sensitive_features sifatida DataFrame [A1, A2] bilan chaqiring — 4 kesishgan guruh uchun aniqlik, TPR, FPR, selection_rate; faqat A1 yoki faqat A2 bo'yicha tahlil kesishma muammosini yashirishini ko'rsating.
5. ThresholdOptimizer(EO) ni birlashgan atribut (A1*2 + A2) bilan qo'llang; 4 usul jadvali; guruhlar soni oshganda har guruhda namuna kamayishi va chegaralar barqarorligi haqida izoh (bootstrap 5 marta).
6. s6 SHAP (GradientBoosting, A'siz): reyting belgisi hissasi 4 guruhda; additivlik.
7. s7 ro'yxati (platforma ishchilari: yuqori xavf — bandlik); ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

15-variant. Kontent moderatsiyasi: izohlarni bloklash — til bo'yicha FPR va matn belgilariga hujum o'rta

Soha: Media (moderatsiya)

Ijtimoiy tarmoq izohlarni 'zararli' deb avtomatik yashiradi; model so'z-sumka belgilarida ishlaydi, rasmli kodlar uchun OCR bor. Sezgir atribut — izoh tili (A=1 ulushi 0.45); tarafkashlik: A=1 tilidagi zararsiz izohlarning 15 % tarixan noto'g'ri bloklangan, vakil belgi — 'noodatiy belgilar ulushi'. Bu variantda adversarial hujum jadval (so'z-sumka) modeliga ham qo'llanadi: belgilar fazosida L_inf buzilish va chegaralangan to'liq sonli (so'z qo'shish) hujum.

Rasm ma'lumoti	sklearn digits, 10 sinf (OCR moduli)
Matn ma'lumoti	sintetik so'z-sumka 6000 x 200 (hisoblagichlar 0-5), 2 sinf
Epsilon to'ri (rasm)	0, 0.05, 0.1, 0.15, 0.2
Epsilon (matn, standartlangan fazo)	0, 0.1, 0.25, 0.5, 1.0; to'liq sonli hujum: 1, 3, 5 so'z qo'shish
EPS_TRAIN	0.1 (rasm)
Sezgir atribut	izoh tili (A=1 ulushi 0.45)
Tarafkashlik	A=1 salbiylarining 15 % flip (ortiqcha bloklash)
Adolatlilik mezoni	false positive rate parity

QADAMLAR

1. s1/s2: digits OCR uchun FGSM va PGD-10 jadvali; assert; grafik.
2. Matn modeli: so'z-sumka generatori + MLP 200-64-2; standartlangan fazoda FGSM/PGD (eps ro'yxati) va to'liq sonli hujum (gradient bo'yicha eng ta'sirli k ta so'z hisoblagichini +1) uchun aniqlik jadvali; qaysi tahdid modeli realistik — izoh.
3. s3 adversarial o'qitish (rasm, EPS_TRAIN=0.1) va matn modeli uchun to'liq sonli hujumga qarshi augmentatsiya; jadval.
4. s4 saliency: rasm uchun panel; matn uchun eng ta'sirli 10 so'z indeksini (|gradient|) chiqaring.
5. s5 generatori: til ulushi 0.45, salbiylarning 15 % flip, noodatiy belgilar ulushi vakil belgi; MetricFrame FPR/TPR; baza, unawareness, ThresholdOptimizer(false_positive_rate_parity), (EO).
6. s6 SHAP (GradientBoosting, moderatsiya sintetik ma'lumoti): noodatiy belgilar hissasi; additivlik; 1 % shovqin barqarorligi.
7. s7 ro'yxati (so'z erkinligi, DSA talablari — cheklangan/yuqori xavf); 13 va 19-bandlar (foydalanuvchi xabardorligi, shikoyat) majburiy; ball va xulosa.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (hujumlar L_inf chegarasida, assert o'tadi) — 30, O'lchovlar va jadvallar (mustahkamlik, adolatlilik, SHAP) — 25, Tahlil va xulosa (mezon tanlovi asoslangan) — 25, Hisobot va tekshiruv ro'yxati sifati — 20

16-variant. Bank: qarz undirish ustuvorligi — kalibrlash, DP va EO mos kelmasligi amalda qiyin

Soha: Moliya (bank)

Bank muddati o'tgan qarzdorlar orasidan 'qattiq undirish' choralarini qo'llanadiganlarni bashorat qiladi; sezgir atribut — hudud (A=1 ulushi 0.4). Generatorda A=1 uchun daromad siljishi parametri bor (0, 0.5, 1.0, 1.5): bazaviy ulushlar farqi oshganda DP, EO va kalibrlashni bir vaqtda qondirib bo'lmasligini ko'rsatish kerak. Qo'shimcha: bank OCR moduliga qora quti (transfer) hujum va in-processing tuzatish talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf; qora quti: kengroq MLP 64-256-256-10
Epsilon to'ri	0, 0.05, 0.1, 0.15, 0.2
PGD	10 va 40 qadam
EPS_TRAIN	0.1
Sezgir atribut	hudud (A=1 ulushi 0.40)
Daromad siljishi (A=1)	0, 0.5, 1.0, 1.5
Tarafkashlik	flip 10 % (doimiy)
Mezonlar	DP, EO, kalibrlash (5 bin), ExponentiatedGradient(EqualizedOdds, 0.02)

QADAMLAR

1. s1/s2: FGSM, PGD-10, PGD-40 jadvali; assert; ko'chuvchanlik: lab MLP'ga qarshi yasalgan namunalarni kengroq MLP'ga bering, 4 eps uchun transfer aniqligi.
2. s3 adversarial o'qitish EPS_TRAIN=0.1; adversarial modelga transfer hujum aniqligi; s4 saliency korrelyatsiyasi toza va adversarial modellar uchun.
3. s5 generatoriga siljish parametri kiriting; har siljish (0, 0.5, 1.0, 1.5) uchun bazaviy ulushlar P(y=1|A) jadvali.
4. Har siljish uchun baza, ThresholdOptimizer(DP), ThresholdOptimizer(EO), ExponentiatedGradient(EO) — DP farqi, EO farqi, aniqlik va guruhlar bo'yicha kalibrlash xatosi (5 bin, |haqiqiy ulush - bashorat ehtimoli| o'rtachasi); 4 x 4 jadval.
5. Grafik: x — siljish, y — DP farqi / EO farqi / kalibrlash xatosi, har usul alohida; siljish oshganda uchala mezonni birga qondirib bo'lmasligini (Kleinberg-Chouldechova) raqamlar bilan ko'rsating.
6. s6 SHAP (GradientBoosting, siljish 1.0 holati): daromad hissasi guruhlar bo'yicha; additivlik; barqarorlik.
7. s7 ro'yxati (qarz undirish: yuqori xavf) + bank uchun 1 sahifalik tavsiya: qaysi mezon, nega, qanday monitoring; ball.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (barcha tekshiruvlar o'tadi) — 25, O'lchovlar, jadvallar va grafiklar — 25, Chuqur tahlil (murozalar, mos kelmaslik, cheklovlar) — 30, Hisobot, model kartasi va tekshiruv ro'yxati sifati — 20

17-variant. Kasalxona: qayta yotqizish xavfi — yosh va jins kesishmasi, ko'chuvchan hujum va detektor qiyin

Soha: Tibbiyot (klinika)

Kasalxona 30 kun ichida qayta yotqizish xavfini bashorat qiladi; ikki sezgir atribut (yosh 65+, jins). Tibbiy ko'rsatkichlar OCR orqali rasmdan olinadi va hujumchi OCR modelining arxitekturasini bilmaydi (qora quti). Sizdan transfer hujum, saliency asosida adversarial detektor (ROC-AUC), kesishgan guruhlar adolatliligi (EO), breast_cancer SHAP va yuqori xavfli tibbiy tizim uchun to'liq tekshiruv ro'yxati talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf; qora quti: sklearn MLPClassifier(hidden 128,64) va o'zgacha PyTorch MLP 64-64-64-10
Epsilon to'ri	0, 0.05, 0.1, 0.15, 0.2
PGD	10 qadam; EPS_TRAIN 0.1
Detektor	saliency entropiyasi + top-5 piksel ulushi, 200 toza + 200 PGD namuna, LogisticRegression, ROC-AUC
Sezgir atributlar	yosh 65+ (0.3), jins (0.5) — 4 kesishgan guruh
Tarafkashlik	keksa ayollar guruhida ijobiylarning 25 % flip; o'lchov shovqini keksalarda 1.5x
Adolatlilik mezoni	equalized odds (kesishma)
SHAP ma'lumoti	breast_cancer, GradientBoosting

QADAMLAR

1. s1/s2 oq quti jadvali; so'ng ikki qora quti modelga transfer aniqligi 4 eps uchun; qaysi arxitektura juftligi ko'proq ko'chadi — izoh.
2. s3 adversarial o'qitish EPS_TRAIN=0.1; adversarial model uchun transfer; jadval va grafik (6 egri chiziq).
3. s4 saliency asosida detektor: 200 toza + 200 PGD (eps=0.15) namuna uchun entropiya va top-5 ulush; LogisticRegression detektor; ROC-AUC va ROC egri chizig'i; eps=0.05 namunalarda AUC qanday tushadi.
4. s5 generatori ikki atributli (yosh, jins), kesishmada flip 0.25 va o'lchov shovqini; MetricFrame 4 guruh (TPR, FPR, FNR); baza, unawareness, ThresholdOptimizer(EO) birlashgan atribut bilan, ExponentiatedGradient(EO).
5. Kalibrlash 4 guruh bo'yicha (5 bin) va FNR farqi — klinik zarar nuqtai nazaridan qaysi metrika birinchi; jadval + grafik.
6. s6 SHAP breast_cancer: top-10, 3 ta namuna (to'g'ri xavfsiz, to'g'ri xavfli, noto'g'ri) lokal izohlari; additivlik; korrelyatsiyalangan belgilar (worst radius/perimeter/area) hissalari taqsimoti.
7. s7 ro'yxati tibbiy tizim uchun (yuqori xavf, MDR/AI Act): 12, 14, 18-bandlar majburiy, xavf toifasi kiritish parametri, bajarilmasa 'joriy etish mumkin emas' xulosasi; ball.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (barcha tekshiruvlar o'tadi) — 25, O'lchovlar, jadvallar va grafiklar — 25, Chuqur tahlil (murozalar, mos kelmaslik, cheklovlar) — 30, Hisobot, model kartasi va tekshiruv ro'yxati sifati — 20

18-variant. HR: rezyume saralash tizimi — to'liq ishonchlilik hisoboti va model kartasi generatori qiyin

Soha: Bandlik (HR tizimi)

Yirik kompaniya rezyumelarni avtomatik saralaydi (jins va yosh — sezgir atributlar) va skanerlangan hujjatlardagi raqamlarni OCR bilan o'qiydi. Yuridik bo'lim audit oldidan Markdown formatida model kartasi + 20 bandli tekshiruv ro'yxatini avtomatik ishlab chiqaruvchi skript talab qiladi: u 1-6 qadam funksiyalarini chaqirib barcha metrikalarni o'lchasin, xavf toifasi parametriga qarab yakuniy xulosa chiqarsin va 60 s ichida ishlasin.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.05, 0.1, 0.2
PGD	10 qadam
EPS_TRAIN	0.1, k = 3 (vaqt chegarasi uchun)
Sezgir atributlar	jins (A1, 0.4) va yosh 45+ (A2, 0.3)
Tarafkashlik	A1=1 ijobiylarining 20 % flip; A2=1 uchun 'oxirgi ish davomiyligi' belgisi siljigan
Adolatlilik mezoni	equalized odds, DP qo'shimcha
Chiqish	Markdown hisobot: model kartasi, metrikalar jadvali, 20 band, xulosa; xavf toifasi = minimal/yuqori; vaqt chegarasi 60 s

QADAMLAR

1. 1-4 qadam funksiyalarini bitta modulga yig'ing (train, fgsm, pgd, adv_train, saliency); toza/FGSM/PGD aniqligini 3 eps uchun, adversarial modelni (k=3) va saliency korrelyatsiyasini o'lchaydigan funksiya yozing; vaqtini o'lchang.
2. s5 generatorini ikki atributli HR ssenariysiga moslang; baza va ThresholdOptimizer(EO) uchun DP/EO farqlari va kesishgan guruhlar jadvali funksiya ko'rinishida.
3. s6 SHAP (GradientBoosting, HR ma'lumoti): top-5 belgilar va additivlik farqini qaytaruvchi funksiya.
4. s7 ro'yxatini kengaytiring: texnik bandlar (7, 8, 9, 11, 20) o'lchovlardan avtomatik, 2 ta yangi band qo'shing (kesishgan guruhlar tahlili; adversarial detektor mavjudligi) — jami 22 band, ball 100 ga normallashtirilsin.
5. Markdown generator: model kartasi (maqsad, ma'lumot, metrikalar, cheklovlar), metrikalar jadvali, tekshiruv ro'yxati jadvali, bajarilmagan bandlar, xulosa; xavf toifasi 'yuqori' bo'lsa 12, 14, 18-bandlar bajarilmaganda 'joriy etish mumkin emas'.
6. Skriptni ikki rejimda ishga tushiring (minimal, yuqori) va ikkala hisobotni saqlang; umumiy vaqt 60 s dan oshmasligini ko'rsating (vaqt jadvali: qaysi qadam qancha).
7. Xulosa: HR tizimi uchun qaysi bandlar texnik ish talab qiladi, 80+ ballga chiqish rejasi; hisobotning auditor uchun yetarliligi haqida tanqidiy baho.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (barcha tekshiruvlar o'tadi) — 25, O'lchovlar, jadvallar va grafiklar — 25, Chuqur tahlil (murozalar, mos kelmaslik, cheklovlar) — 30, Hisobot, model kartasi va tekshiruv ro'yxati sifati — 20

19-variant. Mobil mikromoliya: telefon ma'lumotlari skoringi — vakil belgilarni SHAP bilan fosh qilish qiyin

Soha: Moliya (fintech)

Fintech ilovasi telefon foydalanish ma'lumotlaridan (qo'ng'iroqlar, ilovalar, joylashuv) mikroqarz berishni hal qiladi; sezgir atribut A (hudud, 0.4) belgilar ro'yxatida yo'q, lekin 6 ta belgidan 3 tasi A bilan turlicha kuchda bog'liq. Sizdan vakil belgilar kuchini o'lchash (korrelyatsiya, yordamchi model AUC), SHAP orqali A ta'siri qaysi belgi orqali o'tishini ko'rsatish, vakil belgilarni bosqichma-bosqich olib tashlab aniqlik-adolatlilik egri chizig'ini qurish va OCR moduliga L_2 hamda L_inf hujumlarni taqqoslash talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	L_inf: 0, 0.05, 0.1, 0.15; L_2: 0, 0.5, 1.0, 2.0
PGD	10 qadam (L_inf va L_2 versiyalari); EPS_TRAIN 0.1 (L_inf)
Sezgir atribut	hudud (A=1 ulushi 0.40), belgilarda yo'q
Vakil belgilar	tungi qo'ng'iroqlar (korr 0.6), ilovalar soni (korr 0.35), zaryad sikli (korr 0.15) + 3 ta neytral belgi
Tarafkashlik	A=1 ijobiylarining 20 % flip
Adolatlilik mezoni	demographic parity
SHAP	GradientBoosting, TreeExplainer, guruhlar bo'yicha o'rtacha hissa

QADAMLAR

1. s1/s2: L_inf FGSM/PGD jadvali va L_2 PGD (gradient normalashtirilgan, eps_2 radiusli sharga proyeksiya) jadvali; L_2 va L_inf buzilishlarining ko'rinishini panelda solishtiring.
2. s3 adversarial o'qitish (L_inf 0.1); L_2 hujumga chidamlilik; s4 saliency korrelyatsiyasi.
3. Generator: 6 belgi, uchtasi A bilan berilgan korrelyatsiyada (Cholesky yoki aralashtirish bilan); har belgining A bilan korrelyatsiyasi va A ni bashorat qiluvchi yordamchi model AUC jadvali.
4. s5: baza (A'siz, 6 belgi), ThresholdOptimizer(DP), ExponentiatedGradient(DP); so'ng vakil belgilarni kuchi bo'yicha birin-ketin olib tashlab (3 bosqich) aniqlik va DP farqi egri chizig'ini chizing.
5. s6 SHAP (GradientBoosting, 6 belgi): har belgi uchun o'rtacha SHAP hissasi A=0 va A=1 guruhlarida — farq eng katta belgi A ta'sirini o'tkazuvchi ekanini ko'rsating; additivlik; barqarorlik.
6. Taqqoslash: vakil belgini olib tashlash vs post-processing vs in-processing — aniqlik, DP farqi, inferensda A kerakmi, tushuntirish murakkabligi; jadval.
7. s7 ro'yxati (mikromoliya: yuqori xavf), 5-band (proxy aniqlangan) uchun o'z o'lchovlaringizni dalil qiling; ball va fintech uchun tavsiya.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli,

beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (barcha tekshiruvlar o'tadi) — 25, O'lchovlar, jadvallar va grafiklar — 25, Chuqur tahlil (murozalar, mos kelmaslik, cheklovlar) — 30, Hisobot, model kartasi va tekshiruv ro'yxati sifati — 20

20-variant. Jinoyat sodir etish xavfini baholash: COMPAS uslubidagi sintetik tizim — kalibrlash vs xatolik tengligi qiyin

Soha: Huquqni muhofaza qilish

Sud-huquq tizimi uchun takroriy huquqbuzarlik xavfini baholovchi vositaning sintetik nusxasi tahlil qilinadi: sezgir atribut — guruh (A=1 ulushi 0.45), bazaviy ulushlar haqiqatan farq qiladi (0.45 vs 0.30) va tarixiy hibs yozuvlari A=1 da 1.4 baravar ko'p (nazorat tarafkashligi). Sizdan guruhlar bo'yicha kalibrlangan, lekin FPR/FNR tengsiz model (COMPAS bahsi) ni takrorlash, uchta mezonni birga qondirib bo'lmasligini isbotlash, qarorlar uchun tushuntirish berish va hujjat OCR'iga adversarial o'qitish murozasini EPS_TRAIN bo'yicha o'lchash talab qilinadi.

Rasm ma'lumoti	sklearn digits, 10 sinf
Epsilon to'ri	0, 0.05, 0.1, 0.15, 0.2 (PGD 10 qadam)
EPS_TRAIN	0.05, 0.1, 0.2 (uchta model)
Sezgir atribut	guruh (A=1 ulushi 0.45)
Bazaviy ulushlar	P(y=1|A=0)=0.30, P(y=1|A=1)=0.45
Tarafkashlik	A=1 da 'oldingi hibslar' belgisi 1.4x ko'paytirilgan (nazorat); flip 0
Mezonlar	kalibrlash (10 bin, Brier guruhlar bo'yicha), FPR farqi, FNR farqi, DP, EO
SHAP	GradientBoosting, lokal izohlar 3 shaxs uchun

QADAMLAR

1. s1/s2 FGSM va PGD-10 jadvali; s3 ni EPS_TRAIN = 0.05, 0.1, 0.2 uchun uch marta bajaring: toza aniqlik va PGD aniqligi 4 eps da — 3 x 4 jadval va grafik; radius oshganda muroza.
2. s4 saliency uchta adversarial model uchun: korrelyatsiya o'rtachasi EPS_TRAIN bilan qanday o'zgaradi.
3. Generator: bazaviy ulushlar 0.30/0.45, 'oldingi hibslar' belgisi A=1 da 1.4x; GradientBoosting va LogisticRegression o'qiting; guruhlar bo'yicha kalibrlash (10 bin) va Brier — model kalibrlanganini ko'rsating.
4. MetricFrame: FPR, FNR, selection_rate, TPR guruhlar bo'yicha — kalibrlangan modelda FPR A=1 da sezilarli yuqori ekanini (COMPAS effekti) ko'rsating; nazorat tarafkashligini olib tashlab (1.4x -> 1.0x) farq qancha qoladi.
5. ThresholdOptimizer(EO) va (DP) qo'llang va kalibrlash buzilishini o'lchang; 'kalibrlash + EO + DP' uchala shart bazaviy ulushlar farqlanganda mos kelmasligini jadval va grafikda ko'rsating (nazariy formula bilan solishtiring: FPR/FNR va bazaviy ulush bog'liqligi).
6. s6 SHAP: 3 shaxs (yuqori xavf A=1, yuqori xavf A=0, chegaradagi holat) uchun lokal izohlar; 'oldingi hibslar' hissasi; additivlik; izohni sudya uchun tushunarli tilda yozing.
7. s7 ro'yxati (huquqni muhofaza qilish: yuqori xavf, ba'zi qo'llanishlar taqiqlangan — AI Act 5-modda) : qaysi bandlar texnik jihatdan umuman qondirib bo'lmaydi; umumiy ball va 'joriy etish mumkin emas' asoslari.

Topshiriladi: Kod (.py fayllar, har qadam alohida); Natijalar jadvali (aniqlik vs epsilon, guruhlar kesimida metrikalar, SHAP top-belgilar); Grafik(lar): mustahkamlik egri chizig'i, saliency paneli, beeswarm; To'ldirilgan etik tekshiruv ro'yxati (20 band, dalillar bilan); Xulosa (>= 150 so'z): xavf, adolatlilik mezoni tanlovi va tavsiyalar

Baholash (100 ball): To'g'ri ishlaydigan kod (barcha tekshiruvlar o'tadi) — 25, O'lchovlar, jadvallar va grafiklar — 25, Chuqur tahlil (murozalar, mos kelmaslik, cheklovlar) — 30, Hisobot, model kartasi va tekshiruv ro'yxati sifati — 20